

Week 6 讲义：推理优化与框架生态


核心目标：理解推理优化技术栈，掌握 PagedAttention 原理，能根据场景选择合适的推理框架。

学习时间：5 小时

关键输出：框架选择指南 + 推测解码实践指南

前置要求：已完成 Phase 0 的学习；KV Cache 将在本讲 Part 1 中从工程视角深度展开。

📖 本周知识图谱



🕒 Part 0: 引言——推理为何成为瓶颈？

我们在 Phase 0 中了解到，LLM 的生成过程是 **自回归 (Auto-regressive)** 的：生成第 N 个 token 必须等待第 N-1 个 token 完成。

这种串行特性带来了两个核心挑战：

1. Memory Bound (显存受限)：

- 模型权重本身很大 (7B FP16 $\approx$ 14GB)。
- KV Cache** 随着序列长度线性增长，且必须常驻显存（显存布局与带宽代价详见 Part 1）。

- *例子*：在并发高时，显存往往先于计算单元（Tensor Core）耗尽，导致无法处理更多请求。

Tip

思考题：既然显存这么重要，为什么 GPU 厂商不直接把显存加到 1TB？这背后涉及到物理封装、带宽平衡和商业版图等多重因素。（详见文末[附录：显存墙与 HBM 之困](#)）

2. 低 GPU 利用率：

- GPU 的强大算力经常在“等待数据从显存搬运到计算单元”的过程中被浪费。
- 但这并不是推理全程都如此——推理其实包含两个**截然不同的**阶段。

推理优化的核心目标：在有限的显存中塞入更多的并发请求（提高吞吐），并尽可能减少显存搬运（降低延迟）。

 **关键过渡**：要理解推理优化，首先必须认识到 LLM 推理**不是一个均质过程**。接下来的 Part 0.5 将详细拆解推理的**两阶段模型**，这是理解后续所有优化技术的**元认知框架**。

Part 0.5: 推理的两阶段模型 - Prefill vs Decode 与 PD 分离

在深入后续优化之前，我们需要建立一个**元认知框架**：LLM 推理不是一个均质过程，而是两个截然不同的阶段。

0.5.1 Prefill 阶段 (首次填充)

- **输入**：用户输入的完整 Prompt（例如 500 个 token）。
- **操作**：模型**一次性并行处理**所有 Prompt Token，计算它们的 Key 和 Value，并生成第一个输出 token。
- **计算特性**：
 - **GEMM (矩阵-矩阵乘法)**：权重矩阵与包含 500 个 token 的输入矩阵相乘。
 - **Compute-Bound (计算受限)**：GPU 算力被充分利用，利用率可达 50%+。
 - **耗时**：与 Prompt 长度成正比，但只执行一次。

0.5.2 Decode 阶段 (逐步生成)

- 输入：上一步生成的 1 个 token。
- 操作：模型基于 **KV Cache** 和新 **token**，**串行生成**下一个 token。这个过程不断重复，直到生成结束符 `<EOS>` 或达到最大长度。
- 计算特性：
 - **GEMV (矩阵-向量乘法)**：权重矩阵与只有 1 个 token 的向量相乘。
 - **Memory-Bound (访存受限)**：每一步都要把整个模型权重从显存搬到计算单元，但只做极少量的乘法。GPU 利用率通常 $< 10\%$ 。
 - **耗时**：每一步都很快，但步数等于输出长度，累积耗时可能很长。

💡 深度对标：为什么 Decode 比 Prefill 更"亏"？

维度	Prefill / 训练 (GEMM)	Decode (GEMV)
基本算子	GEMM (Matrix-Matrix)	GEMV (Matrix-Vector)
数据复用	高。1 个权重矩阵与 N 个 token 同时相乘。	极低。1 个权重矩阵只与 1 个新 token 相乘。
瓶颈类型	Compute Bound (计算受限)	Memory Bound (访存受限)
算术强度	$O(N)$ 。计算量增长快于访存量。	$O(1)$ 。每一比特数据搬运只对应极少计算。
GPU 利用率	通常 $> 50\%$ (忙着算)	通常 $< 10\%$ (忙着等数据搬运)

什么是算术强度 (Arithmetic Intensity)? 简单来说就是 `计算量 / 访存量`。在 Decode 阶段，由于每一步都要把 10GB+ 的模型权重从显存搬入核心计算，却只为了服务 1 个 token，这导致 GPU 虽然算力惊人，但因为"运不进来"而处于严重的饥饿状态。

逻辑导向：正因为单请求的 Decode 效率极低，推理框架才必须通过 **Batching**（把多个 GEMV 强行拼回一个 GEMM）来救回效率。

0.5.3 为什么需要 PD 分离思维？

维度	Prefill	Decode
瓶颈	计算 (Compute)	访存 (Memory Bandwidth)
GPU 利用率	高 (50%+)	低 (<10%)
对硬件的诉求	高算力 (TFLOPS)	高带宽 (GB/s)
延迟特性	一次性开销 (TTFT)	累积开销 (TPS)

! Important

核心洞察： Prefill 和 Decode 对资源的诉求是**正交的**。

- 如果把它们混在一起跑（逻辑上共用计算资源），两者会互相干扰：长 Prefill 会阻塞 Decode（增加 inter-token latency），而大量 Decode 请求会占满显存导致新 Prefill 无法启动。
- **PD 分离思想**就是：在调度层面甚至硬件层面，把这两个阶段拆开处理。

0.5.4 PD 分离的工业落地形态

PD 分离的落地是一个**光谱 (Spectrum)**，从"软"到"硬"：

1. **无分离 (Naive)：** Prefill 和 Decode 完全混合调度。这是早期 HuggingFace Transformers 的默认行为，效率最低。
2. **软分离 (Chunked Prefill)：**
 - 将长 Prompt 的 Prefill 切成小块 (Chunk)，与正在进行的 Decode 请求**交替执行**。
 - **目的：** 稳定 inter-token latency，避免长 Prefill 阻塞短 Decode。
 - **代表：** vLLM V1 默认启用，SGLang。
 - **状态：** **事实标准 (De facto standard)**，几乎所有现代推理框架都已采用。
3. **硬分离 (Disaggregated Serving)：**
 - Prefill 和 Decode 运行在**物理上分离的 GPU 集群**。

- Prefill 集群用高算力卡（如 H100 SXM），Decode 集群用高带宽卡或更多 GPU 分摊显存压力。
- KV Cache 通过高速网络（如 NVLink/InfiniBand）从 Prefill 集群传输到 Decode 集群。
- **代表：**字节跳动 Mooncake, 阿里 PAI-Blade, Microsoft Splitwise (论文), PKU DistServe (论文)。
- **状态：**新兴趋势，主要被超大规模 API 服务商采用。

Tip

面试加分点：当被问及"如何优化 LLM 推理"时，先从 PD 分离的视角切入，说明 Prefill 和 Decode 的瓶颈不同，再分别介绍针对性的优化策略（Prefill: Flash Attention, Chunking; Decode: PagedAttention, Batching, Speculative Decoding），会显得非常系统。

Part 1: KV Cache 工程深度解析

Note

本节定位：Phase 0 已从算法视角介绍了 KV Cache 的核心思想（缓存历史 K/V、避免重复计算）。本节从**工程视角**深入：先用三情景对比彻底讲清推理时的前向计算过程（1.1），再依次讲解物理布局（1.2）、带宽代价（1.3）、并发制约（1.4）以及架构层面的 KV Cache 压缩（1.5）。理解这些是读懂 PagedAttention 和后续推理优化的基础。

PD 定位：KV Cache 贯穿 Prefill 和 Decode 两个阶段。

- **Prefill 阶段：**一次性生成所有 Prompt Token 的 K/V，写入缓存。
- **Decode 阶段：**每生成一个新 Token，就往 KV Cache 追加一行——显存问题主要体现在此阶段。

1.1 推理前向计算全景：Prefill、Decode 与 KV Cache

这一节用"三情景对比"的方式，从前向计算的角度彻底讲清 KV Cache 做了什么。符号约定： N = Prompt 长度， t = 已生成的 token 数， d = hidden dimension（单头表示，多头只是把 d 拆为 $H \times d_{\text{head}}$ ，不影响逻辑）。

A. Prefill 阶段（有无 KV Cache，计算完全一致）

Prefill 将完整 Prompt 一次性并行送入模型。

输入： $X \in \mathbb{R}^{N \times d}$ （ N 个 token 的 embedding 堆成矩阵）

Q、K、V 的形态：

$$Q = XW_Q \in \mathbb{R}^{N \times d}, \quad K = XW_K \in \mathbb{R}^{N \times d}, \quad V = XW_V \in \mathbb{R}^{N \times d}$$

三者均为矩阵，行数 = Prompt 长度 N 。

Attention 计算（带 Causal Mask，位置 i 只能看到 $j \leq i$ 的 token）：

$$\text{Output} = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V \in \mathbb{R}^{N \times d}$$

$QK^\top \in \mathbb{R}^{N \times N}$ ，这是一次 **GEMM**（矩阵-矩阵乘法）， N 个位置同时并行计算，GPU 利用率高。

KV Cache 的介入点：Prefill 结束后，将本次计算的 K 、 V 存入缓存：

$$K_{\text{cache}} \leftarrow K \in \mathbb{R}^{N \times d}, \quad V_{\text{cache}} \leftarrow V \in \mathbb{R}^{N \times d}$$

Prefill 阶段的计算本身有无 **KV Cache** 完全相同；区别只是结束时是否将 K/V 保存下来，供后续 Decode 复用。

B. Decode 阶段，无 KV Cache（朴素方案，不可用）

Decode 第 t 步，目标是生成第 $t + 1$ 个输出 token。若没有 KV Cache，必须把完整上下文（Prompt + 已生成的 t 个 token）全部重新送入：

输入： $X_{\text{all}} \in \mathbb{R}^{(N+t) \times d}$ （完整序列，每步都重建）

Q、K、V 的形态：

$$Q = X_{\text{all}} W_Q \in \mathbb{R}^{(N+t) \times d}, \quad K = X_{\text{all}} W_K \in \mathbb{R}^{(N+t) \times d}, \quad V = X_{\text{all}} W_V \in \mathbb{R}^{(N+t) \times d}$$

三者仍为矩阵，但尺寸随 t 不断增长，且 K/V 每步都从零重算（包括 Prompt 部分）。

Attention 计算：

$$\text{Output} = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \in \mathbb{R}^{(N+t) \times d}$$

输出是一个 $(N+t) \times d$ 的矩阵，每一行对应一个 token 位置的上下文表示。由于 Causal Mask，第 i 行只能 attend 到位置 $j \leq i$ ，因此第 i 行代表“看完前 i 个 token 后的状态”，其作用是**预测第 $i+1$ 个 token**。在 Decode 的第 t 步，我们的目标是预测第 $N+t+1$ 个 token，所以只需要最后一行：

$$\hat{y}_{N+t+1} = \text{LM_Head}(\text{Output}[-1, :])$$

致命浪费：前 $N+t-1$ 行对应的是历史位置——这些位置在之前的步骤里已经算过并使用了，现在重算一遍纯属浪费。单步计算量 $O((N+t)^2 d)$ ，随序列平方增长。

C. Decode 阶段，有 KV Cache（实际方案）

同样是 Decode 第 t 步，此时 K_{cache} 和 V_{cache} 已缓存了前 $N+t-1$ 步的历史。

输入： $x_{\text{new}} \in \mathbb{R}^{1 \times d}$ （仅输入最新 1 个 token）

Q、K、V 的形态：

$$q = x_{\text{new}} W_Q \in \mathbb{R}^{1 \times d} \quad (\text{向量，只有 1 行})$$

$$k_{\text{new}} = x_{\text{new}} W_K \in \mathbb{R}^{1 \times d}, \quad v_{\text{new}} = x_{\text{new}} W_V \in \mathbb{R}^{1 \times d}$$

将新 K/V 追加到缓存：

$$K_{\text{cache}} \leftarrow \begin{bmatrix} K_{\text{cache}} \\ k_{\text{new}} \end{bmatrix} \in \mathbb{R}^{(N+t) \times d}, \quad V_{\text{cache}} \leftarrow \begin{bmatrix} V_{\text{cache}} \\ v_{\text{new}} \end{bmatrix} \in \mathbb{R}^{(N+t) \times d}$$

Attention 计算（ q 向量 attend 整个 KV Cache）：

$$\text{output} = \text{softmax}\left(\frac{q K_{\text{cache}}^\top}{\sqrt{d}}\right) V_{\text{cache}} \in \mathbb{R}^{1 \times d}$$

$q K_{\text{cache}}^\top \in \mathbb{R}^{1 \times (N+t)}$ ，这是一次 **GEMV（矩阵-向量乘法）**，只产生 1 行输出，直接用于预测下一个 token。

三情景对比汇总

情景	Q 形态	K 来源	V 来源	Attention 算子	单步计算量
Prefill （有/无缓存一致）	$N \times d$ 矩阵	新算， $N \times d$	新算， $N \times d$	GEMM	$O(N^2d)$
Decode, 无 KV Cache	$(N+t) \times d$ 矩阵	全部重算， $(N+t) \times d$	全部重算， $(N+t) \times d$	GEMM（浪费）	$O((N+t)^2d)$
Decode, 有 KV Cache	$1 \times d$ 向量	历史读缓存 + 新算 1 行	历史读缓存 + 新算 1 行	GEMV	$O((N+t)d)$

三条核心结论：

- Q 的降维：**KV Cache 把 Decode 的 Q 从“ $(N+t)$ 行矩阵”压缩为“1 行向量”，Attention 从 GEMM 降为 GEMV。
- K/V 的来源变化：**无 KV Cache 时每步对全部历史 token 重算 K/V；有缓存时历史部分直接读取，只为新 token 做 1 次投影运算。
- 计算量从平方降为线性：**Decode 从 $O((N+t)^2d)$ 降至 $O((N+t)d)$ ，这是长序列推理得以实用的根本原因。

注意：即使有 KV Cache，Decode 仍然是 Memory-Bound——每一步都要把整个 KV Cache 从显存搬到计算单元（详见 1.3）。KV Cache 消灭了重复算的浪费，但没有消灭读取历史 K/V 这份搬运开销。

具体例子：Prompt “今天 | 天气 | 好”，生成“啊！”

设 $N = 3$ （Prompt 3 个 token），模型 1 层 1 头， $d = 4$ （仅为示意）。

Step 0 — Prefill

$$X = \begin{bmatrix} e_{\text{今天}} \\ e_{\text{天气}} \\ e_{\text{好}} \end{bmatrix} \in \mathbb{R}^{3 \times 4}, \quad Q, K, V \in \mathbb{R}^{3 \times 4}$$

Attention 矩阵（Causal Mask 后， $-\infty$ 位置经 softmax 归零）：

$$QK^{\top} \in \mathbb{R}^{3 \times 3} \rightarrow \begin{bmatrix} a_{11} & -\infty & -\infty \\ a_{21} & a_{22} & -\infty \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \xrightarrow{\text{softmax 逐行}} \begin{bmatrix} 1 & 0 & 0 \\ \cdot & \cdot & 0 \\ \cdot & \cdot & \cdot \end{bmatrix}$$

最后一行 $\rightarrow$ 预测第一个输出 token = "啊"。

保存： $K_{\text{cache}}, V_{\text{cache}} \in \mathbb{R}^{3 \times 4}$

Step 1 — Decode, 输入"啊"

$$x_{\text{new}} = e_{\text{啊}} \in \mathbb{R}^{1 \times 4}$$

$$q = e_{\text{啊}} W_Q \in \mathbb{R}^{1 \times 4} \text{ (向量)}, \quad k_{\text{new}}, v_{\text{new}} \in \mathbb{R}^{1 \times 4}$$

追加后： $K_{\text{cache}}, V_{\text{cache}} \in \mathbb{R}^{4 \times 4}$

$$q \cdot K_{\text{cache}}^{\top} \in \mathbb{R}^{1 \times 4} \xrightarrow{\text{softmax}} \alpha \xrightarrow{\times V_{\text{cache}}} \text{output} \in \mathbb{R}^{1 \times 4} \rightarrow \text{预测 "!"}$$

Step 2 — Decode, 输入"! "

$$q = e_{!} W_Q \in \mathbb{R}^{1 \times 4}$$

追加后： $K_{\text{cache}}, V_{\text{cache}} \in \mathbb{R}^{5 \times 4}$

\$\$ q \cdot K_{\text{cache}}^{\top} \in \mathbb{R}^{1 \times 5} \rightarrow \text{预测} \rightarrow \text{生成结束} \$\$

若无 KV Cache, Step 2 的对比：

$$X_{\text{all}} = \begin{bmatrix} e_{\text{今天}} \\ e_{\text{天气}} \\ e_{\text{好}} \\ e_{\text{啊}} \\ e_{\text{!}} \end{bmatrix} \in \mathbb{R}^{5 \times 4}, \quad Q, K, V \in \mathbb{R}^{5 \times 4}, \quad QK^{\top} \in \mathbb{R}^{5 \times 5}$$

只用最后 1 行结果，前 4 行计算全部浪费。

1.2 KV Cache 的物理布局

在 Transformer 的每一个注意力层中，输入向量通过线性投影得到 K 和 V：

$$K = XW_K \in \mathbb{R}^{s \times d_{\text{model}}}, \quad V = XW_V \in \mathbb{R}^{s \times d_{\text{model}}}$$

在 Multi-Head Attention (MHA) 中， K 和 V 会被拆分成 H 个头，每头维度 $d_{\text{head}} = d_{\text{model}}/H$ 。

关键约束：每一层的注意力计算都是独立的，使用的是**本层自己的** W_K 、 W_V 投影矩阵。因此，KV Cache **无法跨层共享**，每一层都需要独立缓存自己的 K 和 V。

单请求的 KV Cache 布局 (MHA)：

第 l 层 (共 L 层)：

K_cache[l]: shape [s, H, d_head] ← 每生成 1 个新 token, 追加 1 行
V_cache[l]: shape [s, H, d_head]

全部 L 层合计： $2 \times L$ 个张量，每个 shape 为 [s, H, d_head]

精确的显存占用公式 (单请求)：

$$\text{KV_Size} = 2 \times L \times s \times H \times d_{\text{head}} \times \text{bytes} = 2 \times L \times s \times d_{\text{model}} \times \text{bytes}$$

以 LLaMA-3-8B 为例 ($L = 32$, $d_{\text{model}} = 4096$, FP16, bytes = 2)：

序列长度	单请求 KV Cache
1k tokens	$2 \times 32 \times 1024 \times 4096 \times 2 \approx \mathbf{0.5\ GB}$
4k tokens	$\approx \mathbf{2\ GB}$
32k tokens	$\approx \mathbf{16\ GB}$
128k tokens	$\approx \mathbf{64\ GB}$

两个关键特性：

- **Append-Only**：每生成 1 个 token，所有 L 层同时各追加 1 行 K 和 1 行 V，总追加量为 $2 \times L \times d_{\text{model}} \times \text{bytes}$ 。对 LLaMA-3-8B 而言，每个 token 额外占 512 KB 显存。
- **全程驻留**：一个请求的整个生命周期内，其 KV Cache 都必须锁在显存里——换出就要重算，代价极高。

1.3 带宽视角：每个 Token 的搬运代价

Phase 0 的分析集中在"KV Cache 有多大"，但工程上更关键的问题是：**生成每个新 token，实际要搬运多少数据？**

Decode 阶段第 t 步（生成第 $t + 1$ 个 token）的注意力计算：

1. 新 token 经投影得到 $q \in \mathbb{R}^{H \times d_{\text{head}}}$ （仅 1 行）
2. 从显存读取 $K_{\text{cache}}[l]$ （ t 行）和 $V_{\text{cache}}[l]$ （ t 行）
3. 计算 $\text{softmax}(q K_{\text{cache}}^T / \sqrt{d_{\text{head}}}) V_{\text{cache}}$

步骤 2 在第 l 层的带宽开销： $2 \times t \times H \times d_{\text{head}} \times \text{bytes}$

对所有 L 层累加，生成 1 个 token 需从显存读取的 KV Cache 总量：

$$\text{Bandwidth}_{\text{KV}} = 2 \times L \times t \times d_{\text{model}} \times \text{bytes}$$

这与当前序列长度为 t 时 KV Cache 的总大小完全相同——也就是说，**每生成一个 token，就要把整个 KV Cache 搬运一遍。**

Decode 阶段的两类带宽开销（以 LLaMA-3-8B / A100 为例）：

开销来源	数据量（序列长 1k tokens）	数据量（序列长 32k tokens）
模型权重（每步固定）	~14 GB	~14 GB
KV Cache（随序列线性增长）	~0.5 GB	~16 GB
合计	~14.5 GB	~30 GB

核心洞察：在短序列时，模型权重是带宽瓶颈；但在长序列（ $\geq 32k$ tokens）时，KV Cache 的搬运量可与模型权重持平甚至反超，成为**更大的带宽瓶颈**。这正是为什么长上下文推理比短上下文推理慢得多——并不只是因为上下文 Attention 计算量增加，还有这部分带宽压力。

1.4 KV Cache 与并发的张力

KV Cache 不只影响单个请求的延迟，更直接决定了系统能同时服务多少请求。

显存分配等式：

$$\underbrace{\text{GPU 总显存}}_{\text{固定}} = \underbrace{\text{模型权重}}_{\text{固定, 所有请求共享}} + \underbrace{B \times \text{KV_Size}(s_{\max})}_{\text{随并发线性增长}}$$

其中 B 为 Batch Size， $s_{\max}$ 为预分配的最大序列长度。

并发上限：

$$B_{\max} = \frac{\text{GPU 总显存} - \text{权重显存}}{\text{KV_Size}(s_{\max})}$$

以 A100 80GB 部署 LLaMA-3-8B（权重 ≈ 16 GB，FP16）为例：

序列长度上限	单请求 KV Cache	可用 KV 显存	最大并发
4k tokens	2 GB	64 GB	~32 个请求
32k tokens	16 GB	64 GB	~4 个请求
128k tokens	64 GB	64 GB	不足 1 个请求

序列长度翻 8 倍，并发数缩减 8 倍——这正是长上下文推理的核心代价。

早期框架的碎片化问题：在 vLLM 出现之前，大多数框架（如 HuggingFace Transformers）采用**预分配策略**——请求进来时直接按 $s_{\max}$ 申请一整块连续显存。

- **问题：**
 1. **内部碎片：**请求实际只生成了 100 个 token 就结束，剩余 1948 个位置的显存白占。
 2. **外部碎片：**不同请求长度不一，已释放的短序列空间无法被长序列复用。
 3. **无法共享：**Beam Search 或并行采样时，相同的 Prompt KV Cache 被重复存储多份。
- **结果：**显存利用率通常 $< 40\%$ ，实际可服务的并发数远低于理论上限。

这就是 **Part 2 PagedAttention** 要解决的核心问题：在不改变 KV Cache 逻辑语义的前提下，重新设计其物理存储方式，将利用率从 $< 40\%$ 提升至 $> 90\%$ 。

1.5 架构演进对 KV Cache 的影响

Week 2 已从算法角度深讲了 GQA / MQA / MLA，这里从**显存占用**角度重新对齐。

KV Cache 的压缩本质是减少缓存的 KV 头数量或压缩每条 KV 记录的维度：

架构	缓存的 KV 头数	单请求 KV Cache (相对 MHA)	代表模型
MHA	H 个头	$1\times$ (基准)	GPT-2, LLaMA-1
GQA	G 个头 ($G \ll H$)	$G/H \times$ ($H=32, G=8 \rightarrow 1/4\times$)	LLaMA-2/3, Qwen2, Mistral
MQA	1 个头	$1/H \times$ ($H=32 \rightarrow 1/32\times$)	PaLM, Falcon
MLA	低秩压缩向量	约 $d_c/d_{\text{model}} \times$ ($< 1/10\times$)	DeepSeek-V2/V3

MLA 的特殊性（将在 Week 12 详解）：MLA 并非减少头数，而是将 K/V 压缩为一个低秩 latent 向量（维度 $d_c \ll H \times d_{\text{head}}$ ）存入缓存，推理时再通过矩阵乘法解压出完整 K/V。DeepSeek-V2 的实测压缩率约 **93.3%**——在相同显存下，上下文长度或并发数可提升约 14 倍。

工程选型启示：部署时优先选择 GQA 模型（Qwen2.5、LLaMA-3、Mistral）而非 MHA 模型，KV Cache 直接省去 3/4，对长序列并发的提升立竿见影。

💡 Part 2: PagedAttention 原理详解

vLLM 的核心贡献在于将操作系统的 **虚拟内存（Virtual Memory）** 思想引入了 LLM 推理。

Note

PD 定位：PagedAttention 主要是一个 **Decode** 阶段的显存管理优化。

- 它解决的是：每生成一个 Token，KV Cache 就要追加一行，如何避免显存碎片化？
- **但 Prefill 阶段也受益**：通过 Prefix Sharing，多个请求可以共享相同的 Prompt KV Cache。

2.1 核心思想：虚拟内存与分页

在操作系统中，我们在逻辑上认为内存是连续的，但在物理上，内存被切分为一个个离散的 **Page（页）**。

PagedAttention 做了同样的事：

- **逻辑 KV Cache**：对模型来说，KV Cache 依然是连续的张量。
- **物理 KV Cache**：在显存中被切分为一个个固定大小的 **Block**（例如每个 Block 存 16 个 token）。

Note

本质定性：空间优化并非算子优化 PagedAttention 完全不改变 Attention 的数学计算公式 $Attention(Q, K, V)$ 。

- 它改变的是寻址方式（Address Mapping）：从"直接读下标"变成了"查 Block Table -> 读下标"。
- 它优化的是显存利用率（不再有碎片），从而允许更大的 Batch Size，间接提升了吞吐量，但并没有加速单次 Attention 的乘法计算。

2.2 Block 分配机制

1. **按需分配**：当一个新的 token 生成时，如果当前 Block 还有空位，就填入；如果满了，才向 Block Manager 申请一个新的物理 Block。
2. **非连续存储**：逻辑上相邻的 token，其所在的物理 Block 可以散落在显存的任意位置。
3. **Block Table**：类似于操作系统的页表（Page Table），维护逻辑 Block 到物理 Block 的映射关系。

优势：

- **零由于预分配导致的浪费**：几乎消除了内部碎片（每个序列最多浪费最后一个 Block 的一部分）。
- **零外部碎片**：任何物理 Block 都可以被分配给任何请求。

2.3 Prefix Sharing (前缀共享)

这可能是 PagedAttention 最强大的特性之一。

场景：

- **Few-shot Learning**：所有请求都有很长的 system prompt 和示例。
- **Parallel Sampling**：同一个问题，要求生成 5 个不同的回答。
- **Beam Search**。

机制：

- 多个序列的 Block Table 可以指向同一个物理 Block（即 Prompt 部分）。
- **Copy-on-Write**：当某个序列需要修改共享数据（这在 KV Cache 中不会发生，因为是 append-only）或分叉生成不同内容时，新的 token 写入新的非共享 Block。引用计数机制管理 Block 的生命周期。

收益：

- 显存占用大幅降低（对于长 Prompt 场景可降低 50%+）。
- 计算量减少（Prompt 部分的 Attention 只需要计算一次）。

💡 核心比喻： "图书架" vs. "活页夹"

为了更好地理解它的变革性，我们可以使用 **Week 2 提到的经典比喻**：

- **标准方式 (图书架)**： 你给每个作者（请求）分配了一个固定的长书架（连续显存）。哪怕作者目前只写了一句介绍，你也得把之后放 500 本书的空间都腾出来占着。别人想写书没地方放，你这儿却空荡荡。这也是**预分配策略**导致 Batch Size 上不去的原因。
- **PagedAttention (活页夹)**： 你只给作者发一叠**活页纸**。写满一张（Block），你再从仓库里随手拿一张新的补上。这些纸不需要挨在一起放，只要你有一张**目录页**（Block Table）记清楚哪页属于哪个作者就行。结果是：仓库里的纸几乎被 100% 利用，谁也不浪费。

🏆 总结： Attention 优化的双雄

优化技术	优化阶段	计算逻辑是否改变？	核心手段	解决什么瓶颈？
Flash Attention	训练 / Prefill	是 (Tiling + Recomp)	算子融合，在 SRAM 内算完，不写回 HBM	IO 瓶颈 (Memory Bound)
PagedAttention	推理 / Decode	否 (原样计算)	虚拟内存，非连续存储，按需分配	显存容量/碎片 (Capacity Bound)

一句话总结：Flash Attention让你算得快（不存草稿），PagedAttention让你装得多（不留空隙）。两者缺一不可。

Part 3: 推理框架生态

目前市面上的推理框架百花齐放，我们重点关注三个代表性框架。

3.1 vLLM (高适应性/服务端首选)

- 核心技术：PagedAttention + Continuous Batching。
- 特点：
 - 吞吐量极高：得益于高效的显存管理。
 - 易用性：Python 优先，接口类似 HuggingFace，兼容 OpenAI API。
 - 生态好：新模型支持速度极快（通常 24h 内支持）。
 - 支持广泛：FP16/BF16, GPTQ, AWQ, SGLang, LoRA adapter。
- 适用场景：构建高并发的 LLM API 服务，大多数生产环境的默认选择。

Quick Start (vLLM)

```
# 方式 1: 启动 OpenAI 兼容服务器
python -m vllm.entrypoints.openai.api_server --model Qwen/Qwen2.5-7B-Instruct --port 8000
```

```
# 方式 2: Python 脚本调用
from vllm import LLM, SamplingParams
llm = LLM(model="Qwen/Qwen2.5-7B-Instruct")
output = llm.generate("Hello, who are you?",
    SamplingParams(temperature=0.7))
```

3.2 TensorRT-LLM (极致性能/NVIDIA原厂)

- 核心技术：Graph Rewriting, Kernel Tuning, TensorRT 编译器。
- 特点：
 - 性能怪兽：通常比 vLLM 快 20-50%，特别是在 FP8 和 H100 上。

- **编译型**：需要先将模型编译成 Engine 文件（耗时），部署灵活性稍差。
- **C++ 核心**：底层是 C++，上层 Python wrapper，修改底层逻辑门槛较高。
- **适用场景**：对延迟和吞吐有极致要求的生产环境，且硬件固定（如全 H800 集群）。

Quick Start (TRT-LLM)

- Step 1: 编译 (Build Engine)

```
trtllm-build --checkpoint ./qwen_ckpt --output_dir ./qwen_engine
--gemm_plugin float16
```

- Step 2: 运行 (Run)

```
import tensorrt_llm
runner = tensorrt_llm.Runner.from_checkpoint("./qwen_engine")
runner.generate("Hello world")
```

3.3 Ollama (本地部署/开发者友好)

- **核心技术**：基于 llama.cpp (GGUF 格式)。
- **特点**：
 - **CPU/Mac 友好**：深度优化 Apple Silicon 和普通 CPU 推理。
 - **开箱即用**：ollama run llama3 一键启动。
 - **量化优先**：核心是 GGUF 格式的 Int4 量化，适合消费级显卡。
- **适用场景**：本地开发、个人电脑运行、MacBook 用户、边缘设备。

Quick Start (Ollama)

```
# 1. 下载并运行模型（自动处理 GGUF 下载）
ollama run llama3

# 2. 调用 API
curl http://localhost:11434/api/generate -d '{
  "model": "llama3",
  "prompt": "Why is the sky blue?"
}'
```

3.4 LMDeploy (国产之光/TurboMind)

- **核心技术：** TurboMind 推理引擎 (C++) + Persistent Batching。
- **背景：** 上海人工智能实验室 (InternLM 团队) 开发。
- **特点：**
 - **极致优化：** 性能直逼 TensorRT-LLM，部分场景下甚至超越。
 - **量化友好：** 原生支持 AWQ / KV Cache Int8/Int4 量化。
 - **Python 接口：** 提供了类似 vLLM 的易用接口，也支持 Gradio 一键启动。
- **适用场景：** 国内生产环境，追求极致性能但又不想折腾 TensorRT 编译的场景。

Quick Start (LMDeploy)

```
# 命令行聊天
lmdeploy chat turbomind Qwen/Qwen2.5-7B-Instruct

# 启动 API Server (兼容 OpenAI)
lmdeploy serve api_server Qwen/Qwen2.5-7B-Instruct --server-port 23333
```

3.5 框架对比与选型指南

特性	vLLM	TensorRT-LLM	Ollama (llama.cpp)	LMDeploy
显存管理	PagedAttention (最优)	PagedAttention (类似)	静态/动态	TurboMind (高性能)
吞吐量	★★★★★	★★★★★★	★★	★★★★★★
易用性	★★★★★★	★★★	★★★★★★	★★★★
新模型支持	极快	较快 (需 NVIDIA 适配)	较快 (社区驱动)	快
硬件支持	NVIDIA, AMD, TPU	NVIDIA Only	NVIDIA, AMD, Apple, CPU	NVIDIA
典型用途	企业级 API 服务	极致性能生产环境	本地/边缘计算	高性能服务



Tip

选型建议：

- 初学者/本地玩：选 **Ollama**。
- 公司部署微调模型：首选 **vLLM**（生态好，坑少，支持 LoRA）。
- 固定硬件的大规模服务：考虑 **TensorRT-LLM** 或 **LMDeploy** 压榨性能。

🔄 Part 4: Batching 策略

为什么 vLLM 比传统 HF Transformers 快这么多？除了显存管理，**调度策略**也是关键。



Note

PD 定位：Batching 策略的核心挑战是如何调度 **Prefill** 和 **Decode** 混合请求。

- **Prefill 请求：**计算量大，一次性占用大量算力。
- **Decode 请求：**计算量小，但需要持续执行直到生成结束。

如果不加区分地混合执行，**长 Prefill 会阻塞 Decode**，导致 inter-token latency 飙升。这就是为什么现代框架引入了 **Chunked Prefill**（参见 Part 0.5）。

4.1 传统 Request-level Batching (Static Batching)

假设 Batch Size = 3，来了 3 个请求：

- Req A: 输出 10 个 token
- Req B: 输出 100 个 token
- Req C: 输出 20 个 token

过程：

1. 所有请求同时开始。
2. 第 10 步：Req A 结束。但 GPU **不能停**，因为 Req B 还在跑。Req A 占用的槽位变空，无法释放，只能 padding 空转。
3. 第 20 步：Req C 结束。继续 padding。

4. 第 100 步：Req B 结束。整个 Batch 完成，返回结果。

问题：短板效应。整个 Batch 的延迟取决于最长的那个请求，短请求被严重拖累，GPU 计算资源大量浪费在 Padding 上。

4.2 Continuous Batching (Iteration-level Batching)

也叫 In-flight Batching。

原理：将调度粒度从"整个请求"细化到 "每一次 Iteration (生成一步)"。

这背后是一个思维方式的根本转变：**不再把 Batch 看作"一组固定的请求"，而看作"一组当前需要计算的 Slot"。**

- **Static Batching (传统方式)：** 可以理解为 "封闭式过山车"。车上坐满了人 (Batch)，有人 (短请求) 中途想下车不行，必须陪着所有人坐完全程。在这个过程中，车门是锁死的，外面排队的人进不来。
- **Continuous Batching (现代方式)：** 可以理解为 "商场旋转门"。
 - **调度器 (Scheduler)** 在每一次生成新的 token 后 (即每一个 Step)，都会暂停下来看一眼。
 - 如果发现 Request A 已经生成了结束符 `<EOS>`，它就立刻把 A 踢出去。
 - 空出来的资源 (显存 Block)，立刻塞进来一个新的 Request D 的首个 token (Prefill 阶段)。
 - **下一轮计算时**，Batch 里就变成了 `[Req B(step 5), Req C(step 20), Req D(step 1)]`。虽然大家的进度不同，但都在同一辆车上跑这一个 Step。

 **代码视角：为什么能插队？**

Static Batching (开发者写死的 Loop)

```
# 这是一个黑盒函数，一旦进去必须等 batch 里所有人生成完才能出来
# 就像过山车使用了安全锁，中途无法上下人
outputs = model.generate(batch_inputs)
```

Continuous Batching (调度器控制的 Loop)

```
# 拆解为 "While True" 循环
while has_requests():
    # 1. 调度器介入：谁跑完了踢走，谁在排队补位
    # current_batch 是动态拼凑的，可能包含 Req A(step 10) 和 Req B(step 1)
    current_batch_inputs = scheduler.schedule()

    # 2. 只跑 "一步" (One Step Forward)
    # 这是一个极快的原子操作
    logits = model.forward_one_step(current_batch_inputs)

    # 3. 更新状态，回到第一步
    # 这里就像旋转门的空隙，每一圈转回来都有机会进出
    scheduler.update_status(logits)
```

过程：

1. Batch 中包含 Req A, B, C。执行一步生成。
2. 第 10 步：Req A 结束。调度器立刻检测到，**马上插入一个新的 Req D 填补 A 的空位。**
3. 第 20 步：Req C 结束。立马插入 Req E。
4. ...

优势：

- **GPU 永远不空转**：始终保持满负载运行。
- **延迟解耦**：短请求做完即走，不需要等长请求。
- **吞吐量大幅提升**：在大并发混杂长短请求的真实场景下，吞吐量可提升 10-20 倍。

Note

Continuous Batching的安全性 & 隔离机制 (Security & Isolation)

很多同学会有疑问：**新请求 D 填补了 A 的位置，会不会"看到" A 的残留信息？**

答案是**绝对不会**。vLLM 通过双重机制保证了严格的请求隔离：

1. 物理隔离 (Physical Isolation - PagedAttention)

- **不同 Block**: Req A 的 KV Cache 存储在 [Block 1, Block 2]。当 A 结束时, 这些 Block 被释放回 Free List。
- **重新映射**: Req D 虽然占据了 Scheduler 中的逻辑空位, 但它会申请**全新的**物理 Block (例如 Block 8)。
- **独立寻址**: D 的 Block Table 只包含 [Block 8]。它根本不知道 Block 1 和 Block 2 的存在, 物理上无法访问旧数据。

2. 逻辑遮蔽 (Logical Isolation - Attention Mask)

- 在计算 Self-Attention 时, 我们会构建一个巨大的 Mask 矩阵。
- 对于 Req D 的计算位, Mask 会将所有**不属于 D**的位置 (包括 A 的残留痕迹、B 和 C 的数据) 全部置为 $-\infty$ 。
- 经过 Softmax 后, 这些位置的权重归零。这意味着从数学上, D 就像在一个真空环境中独自生成, 完全不受干扰。

💡 餐厅比喻升级版

- **Continuous Batching**: 拼桌吃饭。桌子 (显存/计算资源) 利用率很高。
- **物理隔离**: 服务员 (Block Manager) 不仅收走了上一桌的碗筷, 甚至**换了一张全新的桌布** (分配新 Block)。你根本碰不到上一桌的油渍。
- **逻辑遮蔽**: 虽然你和陌生人 (其他请求) 在一张大桌子 (Batch) 上, 但你们之间竖起了**隔音防视挡板** (Attention Mask)。你看不见也听不见他们在吃什么聊什么。

🚀 Part 5: Speculative Decoding (推测解码)

📝 Note

PD 定位: Speculative Decoding 是一个纯 **Decode 阶段** 的加速技术。

- **原理**: Decode 阶段是 Memory-Bound (访存受限), GPU 算力有富余。
- **利用富余算力**: 用小模型快速"猜"下一批 Token, 大模型并行验证, 省去串行等待。

解决了显存和调度问题, 如何让**单个请求**生成得更快 (降低 Latency) ?

5.1 核心思想：大模型验证，小模型干活

大模型（Target Model，如 70B）生成慢，小模型（Draft Model，如 7B 或专门的 Drafter）生成快。

直觉：很多 token 其实很简单（如 "The", "is", 代码中的分号），不需要 70B 模型动用全部脑力去想。

5.2 工作流程 (Draft-Verify)

1. **Draft 阶段：**小模型快速串行生成 K 个 token（比如 K=5）。
 - **耗时：**小，因为模型小。
2. **Verify 阶段：**大模型并行验证这 K 个 token。
 - 大模型一次前向传播（Forward Pass）可以计算序列中每个位置的概率。
 - **耗时：**和大模型生成 1 个 token 差不多。
3. **Accept/Reject：**
 - 大模型对比小模型的预测。如果小模型猜对了前 3 个，第 4 个错了：
 - 保留前 3 个 token。
 - 修正第 4 个 token。
 - 丢弃后续的预测。

5.3 延迟-吞吐权衡

$$\text{Speedup} = \frac{\text{耗时(大模型生成 } K+1 \text{ 个)}}{\text{耗时(小模型生成 } K \text{ 个)} + \text{耗时(大模型验证 } K+1 \text{ 个)}} \times \text{平均接受长度}$$

- **适用场景：**
 - **Bandwidth Bound：**大模型受限于显存带宽（读取权重慢），计算能力有富余。推测解码利用了这些富余的计算能力来验证。
 - **简单输入：**输入越简单，小模型越容易猜对，加速比越高。
 - **限制：**
 - 需要加载两个模型，显存占用增加。
 - 如果接受率（Acceptance Rate）太低，反而会变慢（因为多了小模型的开销和回退开销）。
-

Part 6: 前沿发展与业界动态 (2024-2025)

推理优化是一个快速演进的领域。以下是截至 2025 年初的一些重要进展。

6.1 vLLM 演进：Chunked Prefill 与 V1 架构

vLLM 在 2024-2025 年间持续迭代，其 V1 版本引入了多项重要特性：

- **Chunked Prefill**：将长 Prompt 的 Prefill 阶段切分成小块（Chunk），与 Decode 请求交替执行。
 - **目的**：稳定 inter-token latency，避免长 Prefill 阻塞短请求。
 - **状态**：vLLM V1 中默认启用。
- **Automatic Prefix Caching (APC)**：基于 hash 的 KV Cache 管理，自动复用相同前缀。
- **2025 路线图**：重点包括滑动窗口 Attention、原生 KV 量化、MoE 优化、多模态输入流式处理等。

参考：vLLM 官方博客 - "[vLLM V1: A Major Upgrade to vLLM's Core Architecture](#)" (Jan 2025)

6.2 SGLang 与 RadixAttention

SGLang 是 UC Berkeley Lianmin Zheng 团队（与 vLLM 同源）推出的新一代推理框架：

- **RadixAttention**：一种自动 KV Cache 复用技术，与 PagedAttention 互补。
 - 使用 Radix Tree（基数树）数据结构索引历史 KV Cache。
 - 支持运行时动态匹配前缀，无需预定义。
- **特点**：在结构化输出（JSON、代码）和 RAG 场景下表现优异，适合需要复杂逻辑控制的应用。
- **vLLM vs SGLang**：vLLM 适合高吞吐 API 服务；SGLang 适合需要精细控制的交互式/Agent 场景。

参考：Zheng et al. 2024 - "[SGLang: Efficient Execution of Structured Language Model Programs](#)" (arXiv)

6.3 多头推测解码：Medusa 与 EAGLE

传统 Speculative Decoding 需要额外的 Draft Model。Medusa 和 EAGLE 提出了更高效的方案：

Medusa (2024)

- **核心思想**：在 LLM 最后一层添加多个**并行解码头**，每个头预测未来不同位置的 token。
- **优势**：无需独立的 Draft Model，只需微调新增的解码头。
- **加速比**：2-3x（Medusa-2 可达 2.2x-3.6x）。
- **Tree Attention**：使用树形结构组织候选 token，提高采样效率。

参考：Cai et al. 2024 - "[Medusa: Simple LLM Inference Acceleration Framework with Multiple Decoding Heads](#)" (arXiv)

EAGLE (2024)

- **核心思想**：在特征层面自回归预测，利用 Target Model 的 top-layer 特征训练轻量 Draft 模块。
- **优势**：无需微调 Target LLM，加速更显著。
- **加速比**：3x（比 Medusa 快 1.6x）。
- **EAGLE-3**：结合低/中/高层语义特征，动态生成 Draft Tree。
- **框架集成**：已集成到 vLLM 和 TensorRT-LLM；Amazon SageMaker 2025 年推出基于 EAGLE 的自适应推测解码。

参考：Li et al. 2024 - "[EAGLE: Speculative Sampling Requires Rethinking Feature Uncertainty](#)" (arXiv)

6.4 DeepSeek 推理优化：MLA 与 FlashMLA

DeepSeek 在 2025 年开源周发布了 **FlashMLA**，这是针对其 Multi-head Latent Attention (MLA) 架构的高度优化推理内核：

- **MLA 核心**：通过低秩矩阵压缩 KV Cache，将 KV 表示为压缩的 latent vectors。
 - **收益**：KV Cache 可减少高达 93.3%。
- **FlashMLA 特性**：

- 专为 Hopper GPU (H100/H800) 优化。
- 显存带宽可达 3000 GB/s。
- Paged KV Cache (Block Size = 64)。
- 支持 BF16/FP16/FP8。
- **vLLM 集成**: vLLM v0.7.1+ 支持 DeepSeek 的 MLA + FP8 优化, 吞吐提升 3x, 显存容量提升 10x。

参考: DeepSeek GitHub - "[FlashMLA: Efficient MLA Decoding Kernel](#)" (2025) 参考: DeepSeek-V3 Technical Report (arXiv, 2024)

6.5 业界趋势总结

趋势	代表技术	关键洞察
KV Cache 压缩	MLA, GQA, MQA	从架构层面减少 KV 存储
智能调度	Chunked Prefill, Continuous Batching	细粒度调度, 平衡 Prefill 与 Decode
前缀复用	PagedAttention, RadixAttention, APC	共享 Prompt, 减少重复计算
并行推测	Medusa, EAGLE, Lookahead	多头/多层预测, 减少串行步骤
硬件定制	FlashMLA, FlashAttention-3, FP8	针对 Hopper 等新硬件深度优化

总结与实践启示

核心回顾

1. **PagedAttention** 像操作系统管理内存一样管理 KV Cache, 解决了显存碎片化问题, 是现代推理引擎的基石。
2. **Continuous Batching** 让调度粒度细化到 token 级别, 解决了长短请求并存时的效率问题。

3. **框架选型**：生产环境通常在 **vLLM**（通用）和 **TensorRT-LLM**（极致性能）之间选择。
4. **Speculative Decoding** 是一种用"计算换带宽"的策略，适合降低单个请求的延迟。
5. **前沿方向**：MLA/FlashMLA、Medusa/EAGLE、SGLang 等正在重塑推理优化的技术格局。

实践建议

- **项目实战**：在 Phase 4 的实战中，如果不涉及极端的 QPS 压力，建议直接使用 **vLLM**。它对 HuggingFace 模型支持最好，且内置了 PagedAttention 和 Continuous Batching。
- **显存规划**：始终记住 KV Cache 是显存大户。在部署前，使用 vLLM 的 `gpu_memory_utilization` 参数预留足够的显存给 KV Cache。
- **关注 DeepSeek 生态**：如果使用 DeepSeek-V3/R1 模型，务必关注 FlashMLA 和 MLA 相关优化。

检查点

- [] 理解 PagedAttention 如何解决 KV Cache 碎片化
- [] 能根据场景选择合适的推理框架 (vLLM vs Ollama)
- [] 理解 Speculative Decoding 的加速原理
- [] 了解 Medusa/EAGLE 与传统推测解码的区别
- [] 了解 DeepSeek MLA/FlashMLA 的核心优化思路

参考文献

- **vLLM**: Kwon et al. 2023 - "[Efficient Memory Management for Large Language Model Serving with PagedAttention](#)" (SOSP '23)
- **Continuous Batching**: Yu et al. 2022 - "[Orca: A Distributed Serving System for Transformer-Based Generative Models](#)" (OSDI '22)
- **Speculative Decoding**: Leviathan et al. 2023 - "[Fast Inference from Transformers via Speculative Decoding](#)" (ICML '23)
- **SGLang**: Zheng et al. 2024 - "[SGLang: Efficient Execution of Structured Language Model Programs](#)" (arXiv)

- **Medusa**: Cai et al. 2024 - "[Medusa: Simple LLM Inference Acceleration Framework with Multiple Decoding Heads](#)" (ICML '24)
 - **EAGLE**: Li et al. 2024 - "[EAGLE: Speculative Sampling Requires Rethinking Feature Uncertainty](#)" (ICML '24)
 - **DeepSeek-V3**: DeepSeek-AI 2024 - "[DeepSeek-V3 Technical Report](#)" (arXiv)
 - **FlashMLA**: DeepSeek GitHub - "[FlashMLA Repository](#)" (2025)
-

附录：显存墙与 HBM 之困

针对"为什么 GPU 不直接配更多显存"这一问题的深度解析：

1. 速度之困：HBM 与带宽瓶颈

LLM 推理是典型的 **Memory Bound**（受限于带宽）。如果使用便宜但慢速的 DDR 内存，即便配 1TB，搬运权重的速度也跟不上计算速度，导致模型生成速度极慢。

- **HBM (High Bandwidth Memory)**: 为了实现 TB/s 级别的带宽，GPU 使用了 HBM 技术。它将 DRAM 颗粒像叠罗汉一样堆叠在 GPU 芯片旁边。
- **物理极限**: HBM 通过数千根 TSV（硅通孔）与 GPU 相连，这种布线密度对工艺要求极高。

2. 面积之困：CoWoS 封装与 Reticle Limit

显存不是无限加的，受限于 GPU 封装的"地皮"：

- **中介层 (Interposer)**: GPU 核心和 HBM 颗粒都封装在一个共同的中介层上。
- **光刻极限**: 中介层的面积受限于光刻机的**曝光场极限 (Reticle Limit)**。你在 GPU 旁边多塞一堆 HBM 颗粒，就需要更大的中介层，这会显著降低良率并增加复杂性。

3. 功耗与热量

HBM 堆栈本身和数千根信号线的翻转会消耗大量能量。

- **热管理**: GPU 核心和 HBM 紧挨在一起，产生的热量极其集中。进一步增加显存容量会给散热带来巨大挑战。

4. 商业的手术刀

显存容量是 NVIDIA 划分产品等级的核心手段。

- **防止背刺**：如果游戏显卡（如 RTX 4090）也配 80GB 显存，企业可能会购买廉价的游戏卡组集群，而不是购买利润极高的 H100/H200。

5. 结论：显存墙（Memory Wall）

这就是业界常说的 "**Memory Wall**"。算力的提升速度远超存储带宽和容量的提升速度。

这对我们的启示：在硬件物理极限面前，**PagedAttention** 和 **深层架构优化**（如 **DeepSeek 的 MLA**）才是解决推理成本问题的"软实力"。