

Week 12 讲义：通用能力评测全景 + 垂直能力基准 + 对齐与偏好评测

核心目标：建立"评测即方法论"的系统认知——理解通用能力基准

(GLUE→MMLU→BIG-Bench) 为何一代代被攻破又一代代被替换，掌握代码/数学/推理三大垂直基准的样例与评分方式，理解为什么"主观、无标准答案"的对齐能力必须依赖 LLM-as-Judge 与真实用户众包 (Chatbot Arena)，并认清这些评测方法各自的局限。这是 Phase 6 (大模型评测体系) 的第一周。

学习时间：6 小时 (通用能力评测全景 2h + 垂直能力基准 2h + 对齐与偏好评测 2h)

关键输出：通用基准演进图 + 样例卡、垂直能力基准详解、偏好评测方法对比

前置要求：完成 Phase 0 (模型生命周期基础)；Week 11 已经从 Agent 视角介绍过 Outcome Eval / Trajectory Eval 与 SWE-Bench，本周会从"能力基准"的视角重新审视 SWE-Bench，并把评测方法论进一步向通用/垂直/偏好三个维度展开。

📖 本周知识图谱



🧭 Part 0: 引言——"能力真的变强了吗？"为什么这是个难题

在 Phase 1-5 中，我们一路学习了模型是如何被"造出来"的：预训练学会语言的统计规律，SFT/RLHF/DPO 学会服从指令与人类偏好，推理优化让模型跑得更快，多模态让模型看懂图像和视频，Agent 系统让模型具备行动能力。但每一次技术改进之后，都会跟着一个朴素却难回答的问题：

这次真的变强了吗？强了多少？在哪些方面强、哪些方面没变甚至变弱了？

这正是"评测 (Evaluation)"要回答的问题，也是 Phase 6 的主题。乍看之下，这似乎是个"简单"问题——写几道题考一考不就知道了？但深入之后会发现，这件事比想象中难得多，原因有三层，也恰好对应本周三个 Part：

难题一："通用能力"本身没有边界。 语言模型不是为某个单一任务训练的，它理论上要处理人类所有的知识和语言任务。用什么题目才能代表"通用能力"？一套题目考完就意味着模型"聪明"了吗——这是 Part 1 要回答的问题。

难题二：不同能力维度需要完全不同的评分方式。 数学题有唯一正确答案，代码题需要真正跑起来验证，抽象推理题甚至没有"标准解法"只有"标准答案"。每个垂直领域都需要量身定制的题目设计和评分机制——这是 Part 2 要回答的问题。

难题三：有一大类能力根本没有"正确答案"。 "这篇文章写得好不好""这个回答是否礼貌得体""两个回答哪个更有帮助"——这些对齐 (Alignment) 相关的能力评估，从根本上是主观的、多元的。这是 Part 3 要回答的问题：当没有标准答案时，我们如何评测？

这三层难题还有一个共同的历史规律，贯穿了 LLM 评测的整个发展史：**任何一套基准，从诞生到被"攻破" (Saturate) 的周期都在急剧缩短。** GLUE 用了不到一年就被 BERT 刷穿了天花板；SuperGLUE 撑了两年；MMLU 从 2021 年发布到 2024 年顶尖模型突破 90%，也只用了三年；GSM8K 从"业界标杆"到"接近满分"用了五年——而这个周期在 2024-2026 年进一步压缩到几个月级别。理解这个"出现—攻破—升级"的循环，比记住某个基准的名字更重要，因为它揭示了评测这件事的本质：**基准不是能力的定义，只是能力的代理指标 (Proxy Metric)**，代理指标一旦被针对性优化，就会与真实能力脱钩（这在统计学与经济学中称为 Goodhart's Law，我们会在 Week 13 深入讨论其对 Agent 评测和"评测即优化目标"的影响）。

带着这个"代理指标会失效"的警觉去看接下来的每一个基准，你会发现每一次基准迭代的动机几乎都是同一句话："上一代基准被刷穿/被污染/区分度不够了，所以我们需要一个更难/更干净/区分度更高的新基准。"

Part 1: 通用能力评测全景

1.1 LLM 之前：任务碎片化时代与 GLUE

在 2018 年之前，自然语言处理（NLP）领域没有"通用语言模型"的概念——每一类任务（情感分类、文本相似度、自然语言推理.....）都有专门设计、专门训练的模型，彼此互不相通。这种碎片化带来一个直接问题：**如何知道一个新的模型架构或预训练方法是否真的更好？** 如果每个任务都要单独收集数据、单独训练、单独评测，不同论文之间的结果根本无法横向比较。

GLUE（General Language Understanding Evaluation, Wang et al., 2018, 纽约大学/华盛顿大学/DeepMind）正是为了解决这个问题而生：把 9 个具有代表性的语言理解任务打包成一套"综合体检套餐"，任何模型只要在这 9 个任务上分别微调、分别测试，就能得到一个可横向比较的综合分数。

任务	类型	示例
CoLA	语法可接受性判断	"The book what Mary read was long." → 不合语法
SST-2	情感二分类	"This movie is fantastic." → 正面
MRPC	句子对语义相似度	判断两句话是否表达同一个意思
STS-B	句子对相似度打分（0-5 连续值）	比 MRPC 更细粒度
QQP	Quora 问题对是否重复	判断两个提问是否是同一个问题
MNLI	自然语言推理（三分类）	前提句能否推出/矛盾/无关于假设句
QNLI	问答式自然语言推理	句子是否包含问题的答案
RTE	文本蕴含判断	类似 MNLI 但数据规模更小
WNLI	Winograd 代词消歧改编	需要常识才能确定代词指代对象

评分方式：每个子任务用各自最合适的指标（准确率、F1、皮尔逊相关系数等），最后取宏平均得到一个 GLUE 综合分。这是"多任务打包+统一排行榜"这一评测范式的开创性尝试，此后几乎所有的通用能力基准都沿用了"多任务合并成一个分数"的设计思路。（各任务的具体 Train/Dev/Test 数据量见附录 A.3——你会看到 9 个任务的数据规模差异很大，从几百到几十万不等，这本身也反映了当时 NLP 各任务"数据可得性"的巨大差异。）

GLUE 的命运：2018 年发布时，人类基线约 87 分，最好的模型只有 70 分左右，是一个真实存在的差距。但 2018 年底 BERT 发布后，仅用了几个月分数就逼近人类基线；到 2019 年，多个模型已经**超过了人类基线**——GLUE 在不到一年内被"攻破"。

1.2 SuperGLUE：拉大差距的尝试

GLUE 被攻破后，同一批作者在 2019 年推出了 **SuperGLUE**，思路很直接：既然 GLUE 的任务对模型来说太容易，那就换成一批人类和模型差距明显更大的任务。

任务	类型	为什么更难
BoolQ	段落理解 + 是非问答	需要真正读懂一整段文字
CB (CommitmentBank)	蕴含判断	需要判断说话者对命题的确信程度
COPA	因果推理二选一	"前提事件的原因/结果最可能是选项1还是选项2"
MultiRC	多句子联合推理问答	答案可能需要综合多个句子才能得出
WiC (Word-in-Context)	词义消歧	同一个词在两句话中是否表达相同含义
WSC (Winograd Schema Challenge)	代词指代消歧	经典常识推理挑战，如"奖杯放不进箱子里因为它太大"中"它"指代什么
RTE / ReCoRD	蕴含判断 / 阅读理解填空	沿用/升级自 GLUE

SuperGLUE 上线时人类基线约 89.8 分，最好的模型只有 71.5 分，差距被重新拉开到接近 20 分。但这一次的"续命"只持续了约一年半——2021 年 1 月，微软的 **DeBERTa** 以 89.9 分**首次超过**人类基线，其 ensemble 版本进一步冲到 90.3；此后 ERNIE 3.0、Vega 等模型接连刷新纪录。SuperGLUE 从那时起就已经从"有区分度的基准"退役——今天的前沿模型技术报告基本不再汇报 SuperGLUE 分数，因为它早已失去区分度，这正是 Part 1.6 要总结的"基准被刷穿后被替代"规律的一次提前预演。

这里有一个容易搞混但很重要的细节：**真正刷穿 SuperGLUE 的是 T5、DeBERTa、ERNIE 3.0 这类针对每个任务单独微调的"专家模型"**，而不是 **GPT-3**。GPT-3 论文里用的是少样本（few-shot，32 个示例）设置测 SuperGLUE，报告的平均分只有 71.8——比人类基线低了 18 分，比同期微调 SOTA（89.0）也明显更低。这个对比恰好印证了 1.3 节讲过的"zero/few-shot 与微调是两种完全不同的评测协议"：同一个基准，用"少样本泛化"和"任务微调"两种方式测，同一时期的分数可以相差近 20 分，脱离协议谈"模型有没有超过人类"是没有意义的。（各任务的具体 Train/Dev/Test 数据量见附录 A.3——相比 GLUE，SuperGLUE 里有几个任务如 CB/COPA/WSC 的数据规模明显更小，这是"任务难度"与"数据规模"权衡的直接体现。）

这里出现了本周要反复看到的第一个规律：**每一次"造一个更难的基准"**，本质上都只是在**延缓被攻破的时间，而不是解决问题本身**。GLUE→SuperGLUE 的升级方式（换更难的任务、拉大与人类的差距）后来被证明只是权宜之计，真正的范式转变发生在下一步。

1.3 知识时代的到来：MMLU

GLUE/SuperGLUE 有一个共同的局限：它们测的都是"语言理解"任务（判断语法、判断相似度、判断蕴含关系），几乎不涉及"世界知识"。但 GPT-3 展示出的能力已经远超"语言理解"——它似乎在预训练过程中"记住"了大量百科式知识。怎么测这种知识广度？

MMLU (Massive Multitask Language Understanding, Hendrycks et al., 2021, UC Berkeley) 给出的答案是：覆盖 **57 个学科** 的选择题集合，从高中水平到大学专业水平再到职业资格考试水平都有，共约 1.4 万道测试题，涵盖 STEM（数学、物理、计算机.....）、人文（历史、哲学、法律.....）、社会科学（经济学、心理学、社会学.....）和其他（营养学、市场营销.....）四大类别。

样例剖析（改编自公开题库风格，展示典型的 MMLU 输入输出格式）：

学科: `abstract_algebra` (抽象代数)

问题: Find the degree for the given field extension $\mathbb{Q}(\sqrt{2}, \sqrt{3}, \sqrt{18})$ over $\mathbb{Q}$.

选项:

- (A) 0
- (B) 4
- (C) 2
- (D) 6

参考答案: (B)

Few-shot 提示格式：MMLU 的标准评测协议是 **5-shot**（提供 5 个同学科的示例问答，再让模型回答第 6 个真正的测试问题），而不是 zero-shot 直接问。这个设计选择本身值得注意——它考察的不完全是模型"裸的"知识水平，还包含模型能否从少量示例中学会"这道题该用什么格式回答"的能力（**In-Context Learning**，情境学习）。

- **Zero-shot**：不给任何示例，直接问模型，最接近真实部署场景，但模型可能因为不理解题目格式而答错（并非真的不会）

- **Few-shot**: 先给 K 个同类型的示例（通常 K=5），模型据此推断输出格式和答题风格，再回答目标问题——这是 MMLU 官方协议采用的方式

这个区分很重要：**同一个模型在 zero-shot 和 few-shot 设置下的 MMLU 分数可能相差好几个百分点**，如果两篇论文用不同的 shot 数汇报分数，直接比较数字是不公平的。这也是后续评测框架标准化（如开源的 `lm-evaluation-harness`）的动机之一——统一 shot 数、统一 prompt 模板，减少"同名基准、不同分数"的乱象。

1.4 评分方式的分裂：Log-likelihood 打分 vs 生成式匹配

MMLU 这类多选题基准还隐藏着一个容易被忽略、但工程上非常重要的细节：**同一道选择题，有两种完全不同的评分方式**，会导致同一个模型报出不同的分数。

方式一：Log-likelihood 打分（对数似然打分）

这是早期（GPT-2/GPT-3 时代非 Chat 模型）的标准做法。不要求模型真正"生成"答案，而是分别计算模型在给定题目+选项拼接后，对每个选项标签（A/B/C/D）token 的对数似然（log-probability），取概率最大的选项作为模型答案。

```
# 伪代码：log-likelihood 打分方式
for choice in ["A", "B", "C", "D"]:
    prompt = f"{question}\n{choices_text}\nAnswer: {choice}"
    logprob = model.compute_logprob(prompt, target=choice)
    scores[choice] = logprob
predicted = argmax(scores) # 取对数似然最大的选项
```

这种方式的优点是**不依赖模型的指令遵循能力**——即使模型从没学过"请输出 A/B/C/D"这种指令格式，只要它对正确答案的内在概率更高，就能被正确评分。缺点是**必须能拿到模型的 logits**，闭源 API（尤其是 Chat 模型的对话接口）往往不提供逐 token 概率，导致这种方式在 API 模型上无法直接使用。

方式二：生成式匹配（Generative / Answer Extraction）

让模型按照对话形式正常生成一段文本回答，再用规则（正则表达式）或者另一个模型从生成文本中抽取出最终选择的选项字母，与参考答案比较。

```
# 伪代码：生成式匹配打分方式
response = model.generate(f"{question}\n{choices_text}\nPlease answer with
```

```
the letter only.")
predicted = extract_answer_letter(response) # 正则提取, 如 "答案是 (B)" → "B"
```

这更接近真实使用场景（用户看到的就是生成文本），但评分结果对 **prompt 措辞、答案抽取规则的鲁棒性高度敏感**——如果模型输出"我认为答案应该是选项 B，因为....."而抽取规则只匹配"`^[A-D]$`"这种严格格式，就会误判为答错。

这个分裂造成了真实的工程后果：不同评测框架（官方论文 vs 开源 `lm-evaluation-harness` vs 各厂商自己的评测脚本）经常在同一个基准上因为评分方式不同，报出相差好几个百分点的分数，这也是"模型能力排行榜"长期存在争议的原因之一——**报出来的数字，一半取决于模型能力，另一半取决于评测框架的实现细节**。这是每一个想严肃对比模型能力的工程师都要面对的第一课：**永远先确认对方用的是什么评测框架、什么 shot 数、什么评分方式，再比较数字。**

1.5 饱和与反击：MMLU-Pro / BIG-Bench(Hard)

到 2024 年，顶尖模型在 MMLU 上的分数已经普遍超过 90%，逼近甚至超过"人类专家"基线（约 89.8%）。这一次饱和背后有两个原因交织在一起，而且很难分离：

1. **真实能力提升：**模型确实变得更博学、推理更强了
2. **训练数据污染：**MMLU 于 2021 年公开发布，此后大量出现在互联网文本、学术论文引用甚至教育类语料中，后续模型的预训练语料几乎不可能完全避开它——模型可能不是"推理"出答案，而是"背"出了答案

这两个原因无法通过分数本身区分，这正是 Week 13 会深入讨论的"污染检测"问题的根源。这里先给出针对 MMLU 饱和问题的两条应对路线：

路线一：提高单题难度和区分度——MMLU-Pro (TIGER-Lab, 2024)

- 选项数从 4 个增加到 **10 个**，大幅降低"瞎猜"的正确率（4 选项瞎猜 25%，10 选项瞎猜仅 10%）
- 过滤掉容易被模型"抄近道"解出的简单题目和存在噪声/歧义的题目
- 增加了需要多步推理才能解出的题目比例，而不只是知识回忆
- 结果：顶尖模型在 MMLU-Pro 上的分数普遍比 MMLU 低 15-20 个百分点，重新拉开了模型之间的区分度

路线二：拓宽任务的"广度"和"怪异度"——**BIG-Bench**（Google + 400 余位社区贡献者，2022）

- 由社区众包贡献 **200 多个** 风格迥异的 任务，很多任务专门设计用来"钻模型的空子"（暴露反直觉的失败模式），比如需要理解讽刺、识别逻辑谬误、下国际象棋残局等
- 体现了与 MMLU（学科知识导向）完全不同的设计哲学：**不追求覆盖"标准知识"，而是追求捕捉模型意料之外的弱点**
- 衍生出 **BBH（BIG-Bench Hard）**（Suzgun et al., 2022）：从 200+ 任务中挑出 **23 个** 模型表现明显低于人类平均水平的困难子集，因为需要真正的多步推理，后来成为业界评测"推理能力"的标准子集之一，也是 Chain-of-Thought 提示方法最早期验证效果的重要测试床之一

1.6 演进逻辑总结

把本节的演进链画出来，能清楚看到每一步升级要解决的是上一代的哪个具体局限：

演进	上一代的局限	这一代解决了什么	这一代留下了什么新局限
GLUE → SuperGLUE	任务太简单，模型很快追平人类	换成更难、更需要常识推理的任务	依然只是"语言理解"，缺乏世界知识考察
SuperGLUE → MMLU	不考察知识广度，任务类型单一（都是分类/推理）	57 个学科的知识+推理综合测试	few-shot 协议引入格式依赖；仍是静态数据集，会被记忆
MMLU → MMLU-Pro	4 选项瞎猜率高，简单题混入太多，2021 年数据已被广泛"记忆"	10 选项 + 过滤简单题，重新拉开区分度	依然是静态数据集，长期来看仍会被"消化"
MMLU → BIG-Bench(Hard)	学科知识框架内的任务同质化，缺乏"意外性"	社区众包多样化任务，捕捉反直觉失败模式	200+ 任务质量参差不齐，需要挑出 BBH 子集才实用

这条链背后真正的驱动力，从始至终都是同一句话：上一代基准"太容易被刷穿"（无论是因为任务简单，还是因为静态数据被训练数据"消化"）。这个规律不会在 MMLU-Pro 这里停止——你在 Part 2 会看到代码和数学基准完全重复了同一套逻辑，Part 3 里对齐评测则给出了一个更彻底的解法：**放弃静态数据集**。



Part 2: 垂直能力基准：代码/数学/推理

通用能力基准（Part 1）用选择题衡量"知识广度"，但选择题有一个本质缺陷：**它测的是"识别正确答案"的能力，而不是"生成正确答案"的能力**——这对代码、数学这类需要真正"做出来"才算会的任务是不够的。垂直能力基准的核心设计变化，正是从"选择题"转向"生成后验证"：让模型自由生成一段代码/一段推导，再用一套**可自动化、客观**的验证机制（跑测试用例、比对最终数值、检查证明逻辑）来判断对错。这种"生成+自动验证"的模式，也让代码和数学成为大模型评测中**受污染影响相对更容易应对**的领域——因为验证环境本身可以自动生成新题，而不必永远依赖同一批静态题目。

2.1 代码能力：HumanEval → LiveCodeBench → SWE-Bench

HumanEval（Chen et al., 2021, OpenAI Codex 论文）是代码生成评测的起点：164 道手写的 Python 编程题，每题包含函数签名、英文文档字符串（docstring）描述功能，以及若干隐藏的单元测试。

样例剖析（HumanEval 中最广为人知的第 0 题）：

输入（函数签名 + docstring）：

```
def has_close_elements(numbers: List[float], threshold: float) -> bool:
    """ Check if in given list of numbers, are any two numbers closer
    to each other than given threshold.
    >>> has_close_elements([1.0, 2.0, 3.0], 0.5)
    False
    >>> has_close_elements([1.0, 2.8, 3.0, 4.0, 5.0, 2.0], 0.3)
    True
    """
```

期望输出：模型补全函数体，使其通过隐藏测试用例

评估方式：实际执行补全后的代码，跑通所有隐藏 unit test 才算通过

评分指标：pass@k。因为代码生成存在随机性（同样的 prompt，采样多次可能得到不同的实现），HumanEval 用 **pass@k** 衡量"给模型 k 次尝试机会，至少一次通过的概率"：对每道题采样 n 次 ($n \geq k$)，统计其中通过测试的样本数 c，用无偏估计公式计算 pass@k 的期望值（完整推导见附录 A.2）。工程上常见的报告口径是 **pass@1**（单次生成尝试的正确率，最贴近真实使用体验）。

MBPP (Mostly Basic Python Problems, Austin et al., 2021, Google) 是同一时期的姊妹基准，974 道众包收集的短 Python 编程题，题目风格更贴近初学者日常练习。

局限与污染问题：HumanEval/MBPP 都是短函数级任务，脱离真实软件工程的复杂度（真实 bug 往往涉及多文件、需要理解已有代码库上下文）；而且这两个数据集发布于 2021 年，早已被大量后续模型的预训练语料"消化"——高分不再能确定性地代表真实编程能力。

LiveCodeBench (Jain et al., 2024, UC Berkeley/MIT/Cornell) 给出了一个思路清晰的解法：从 LeetCode、AtCoder、Codeforces 等平台持续抓取新题目，并按题目发布时间切片——只用"模型训练数据截止日期之后"发布的新题目来评测，从数据层面天然规避污染问题。这种"用时间戳防污染"的思路非常重要，你会在 Part 2.2 的数学基准和 Week 13 的污染检测方法中反复看到它的变体。LiveCodeBench 除了代码生成，还覆盖代码执行结果预测、代码自我修复 (Self-Repair) 等更贴近真实开发场景的任务类型。

SWE-Bench (Jimenez et al., 2023, Princeton) 代表了代码评测"任务真实性"维度的一次跃升——我们在 **Week 11 Part 3.3** 已经从 Agent 评测的角度详细介绍过它（真实 GitHub issue、仓库级代码定位、Resolve Rate 指标、SWE-Bench Verified 的人工核验版本）。这里从"垂直能力基准"的视角重新定位它：与 HumanEval 相比，SWE-Bench 的本质区别不是"更难的算法题"，而是**任务粒度的根本改变**——从"给定清晰函数签名，补全一个独立函数"，跃升到"给定一句模糊的人类 bug 描述和一个几十万行代码的完整仓库，自主定位问题、跨文件修改、通过真实测试套件"。这正是为什么 SWE-Bench 常被同时归类为"代码能力基准"和"Agent 能力基准"——它考察的是"代码理解+定位+修改+验证"的完整闭环，而不只是单点的代码生成能力。Week 13 会从 Agent 视角对它做更深入的 Trajectory 分析。

2.2 数学能力评测

GSM8K (Grade School Math 8K, Cobbe et al., 2021, OpenAI) 是数学推理评测的经典起点：8500 道小学水平的应用题，需要 2-8 步基础算术推理才能解出。

样例剖析 (GSM8K 论文中被引用次数最多的例题，也是早期 Chain-of-Thought 论文中反复使用的示范案例)：

问题: Natalia sold clips to 48 of her friends in April, and then she sold half as many clips in May. How many clips did Natalia sell altogether in April and May?

参考解法 (自然语言分步推导)：

Natalia sold $48/2 = 24$ clips in May.

Natalia sold $48+24 = 72$ clips altogether in April and May.

参考答案：72

评分方式：精确匹配最终数值答案 (不要求推导过程完全一致)

GSM8K 的历史意义不只在它本身，还在于它是 **Chain-of-Thought (思维链)** 提示方法最早、最著名的验证测试床之一——"让模型先写出分步推理再给出答案"这一提示技巧，正是在 GSM8K 这类多步算术题上首次展现出压倒性的效果提升，此后成为几乎所有推理任务的标准提示范式。

MATH (Hendrycks et al., 2021, UC Berkeley) 比 GSM8K 难得多：12500 道高中/数学竞赛水平的题目，覆盖代数、几何、数论、概率等分支，答案通常需要 LaTeX 格式的符号表达式而非单一数字，评分需要处理数学表达式的等价性判断 (如 $1/2$ 与 0.5 是否算匹配)。

饱和与升级：到 2024 年，GPT-4/o1 级别的模型在 GSM8K 上已经普遍超过 95%，在 MATH 上也大幅逼近满分——这两个基准对于评测最前沿模型已经**失去区分度**。业界的应对路径延续了 Part 1.5 见过的同一套逻辑：换更难的题。

- **AIME** (American Invitational Mathematics Examination, 美国数学邀请赛)：这不是专门为 LLM 设计的基准，而是**真实存在的高中数学竞赛** (面向 AMC 竞赛的高分选手)，社区直接把每年的真实赛题拿来评测模型。由于比赛**每年出新题**，天然具有类似 LiveCodeBench 的"时间切片抗污染"效果——只要用"模型发布日期之后"举

行的那一年比赛题，就能保证模型没在训练数据中见过。2025 年的 AIME 赛题被广泛用作评测 o1/o3/DeepSeek-R1 等推理模型的核心基准之一（“每年出新题”设计的三个代价——跨年可比性、题量统计噪声、饱和加速——详见附录 A.6）。

- **OlympiadBench** (He et al., 2024)：奥林匹克竞赛级别的双语（中英）、多模态（部分题目含几何图形）数学与物理题库，比 AIME 覆盖的学科范围更广。
- **FrontierMath** (Glazer et al., 2024, Epoch AI)：由专业数学家专门为评测设计并撰写、从未公开发表的原创难题，覆盖数论、代数几何、微分方程等前沿数学分支。题目难度是“研究级”的——即使是相关分支的数学博士也常常需要数小时甚至数天才能解出一道题。FrontierMath 按难度分为 Tier 1-4，Tier 4（最难档）的题目最初被称为“数学界对 LLM 设的终极考题”，早期最强模型的解出率也只有个位数百分比。2026 年 6 月，Epoch AI 发布了一次重要的数据集修订，修正了此前约 42% 题目中存在的表述或答案错误，这个事件本身是一个很好的提醒：**即便是专家精心设计的高质量基准，数据质量问题也会持续暴露，评测基准本身需要像软件一样“打补丁”。**

2.3 通用推理能力评测

除了知识（Part 1）和特定领域技能（代码/数学），还有一类基准专门考察不依赖专业知识、更接近“抽象推理能力”本身的题目。

ARC-AGI (Abstraction and Reasoning Corpus, Chollet, 2019, 出自论文《On the Measure of Intelligence》) 设计理念极为独特：题目是一系列彩色方格构成的输入-输出网格变换对（类似 IQ 测试中的图形推理题），模型需要从少量示例中归纳出隐藏的变换规则，再应用到新的输入网格上。

示例任务（简化示意）：

示例1：输入网格中一个 2x2 的红色方块 → 输出网格中该方块被复制到镜像对称位置

示例2：输入网格中一个 2x2 的蓝色方块 → 输出网格中该方块被复制到镜像对称位置

测试：给定一个新的方块位置和颜色 → 模型需要推断“镜像复制”这条规则并生成正确输出网格

ARC-AGI 的核心设计哲学是**抗记忆、抗刷题**：每道题的变换规则都是独特的，模型无法通过“背下所有可能规则”来作弊，唯一能拿高分的方式是具备“少样本归纳新规则”的真正泛化能力。这也是它被作者称为衡量“智能”（而非“知识量”）的原因。2024 年 ARC Prize 竞赛设立后，社区涌现大量针对 ARC-AGI 的专门优化方案（包括程序合成、暴力搜索等技巧性很强的解法），暴露出“即使设计再巧妙的静态基准，也可能被针对性地‘攻克’而非

被'真正解决'"这一问题；为此 **ARC-AGI-2** (ARC Prize Foundation, 2025) 作为升级版发布，进一步提高了对纯记忆/暴力枚举策略的抵抗力，强调任务必须要求真正的组合推理才能解出。

ARC-AGI-3 (ARC Prize Foundation, 2026-03-25 发布, 预览版 2025-07, 论文 arXiv:2603.24621) 把这一逻辑推到了更根本的层面：它是系列中第一个**交互式推理基准** (Interactive Reasoning Benchmark)。评测对象面对的不再是静态网格谜题，而是一个**回合制的抽象小游戏环境**——agent 被放入一个从未见过的环境中，**不被告知任何任务目标**，必须依靠试探性动作自行探索环境动力学、推断"这一关的目标是什么"、建立内部的世界模型，并据此规划动作序列。评分方式也同步从"通过/不通过"改为 **RHAE (Relative Human Action Efficiency, 相对人类动作效率)**：不仅要求通关，还以人类完成同一环境所用的动作数为基准衡量效率，把"高效探索"正式纳入智能的度量。

ARC-AGI-3 发布时产生了 2026 年评测领域最具冲击力的结果：**人类基线约 100%，而所有前沿模型得分全部低于 1%**——Gemini 3.1 Pro 0.37%、GPT-5.4 0.26%、Claude Opus 4.6 0.25%、Grok-4.20 0.00%（均为一手来源确认的数字）。更耐人寻味的是：30 天开发者预览中，一套简单的 CNN 表征 + 图搜索的专门方法即达到 12.58%，数倍于所有通用大模型——这强烈提示通用 LLM 在"交互式探索 + 在线目标推断"上的缺口是**结构性**的，而非单纯的规模问题。从评测演进的角度看，ARC-AGI-3 是"难度升级"逻辑的极端形态：一次发布直接把区分度从"濒临饱和"重置到"接近零点"，同时把评测范式从"静态问答"整体推进到"agentic 交互"——它考察的能力栈（探索、目标推断、世界模型、序列规划）与 Week 11 讨论的 Agent 能力栈高度重合，是"能力评测"与"Agent 评测"开始合流的标志性事件。

一个对工程实践极具启发的后续案例：OpenAI 在发布后的官方复测中发现，同一模型 (GPT-5.6) 在官方默认 harness 下得分 13.3%，仅开启 **retained reasoning 与 compaction**（保留推理轨迹 + 上下文压缩，机制见专题《Harness工程与上下文工程》）两项 harness 配置后，得分即升至 38.3%——接近三倍的差距全部来自模型之外的"外骨骼"。这与 Part 1.4 "评分方式影响分数"是同一主题在 agentic 时代的升级版：**当评测对象从"裸模型"变成"模型 + harness"系统，分数就不再是模型固有的属性，而是整个系统的属性**——跨厂商比较 agentic 基准分数时，必须先问清楚"harness 是什么"。

BBH (BIG-Bench Hard)：已在 Part 1.5 介绍过，是从 BIG-Bench 200+ 任务中筛选出的 23 个高难度推理子集，常与 Chain-of-Thought 提示搭配使用，作为衡量"多步推理能力"的标准子集。

MuSR (Multistep Soft Reasoning, Sprague et al., 2023) 用程序化生成的叙事文本（如推理小说式的谜案、团队分配问题、物品摆放推理）考察模型的多步"软推理"能力——之所以称为"软"推理，是因为线索往往不是形式化的逻辑命题，而是嵌入在自然语言叙述中的隐含信息，需要模型综合多条线索才能得出唯一确定的结论。程序化生成的好处是可以按需生成任意数量的新题，天然规避了静态数据集被"记忆"的问题。

DROP (Discrete Reasoning Over Paragraphs, Dua et al., 2019) 把阅读理解和离散数值推理结合起来：问题的答案不能直接从原文中摘抄，而需要对提取出的实体或数字进行加减、计数、排序等离散运算（例如"这篇报道中提到的两次进球时间相差多少分钟"），检验模型能否把"理解文本"和"符号化运算"两种能力结合起来。

2.4 共性规律总结

领域	早期基准	升级路径	核心评分机制	抗污染手段
代码	HumanEval / MBPP	→ LiveCodeBench → SWE-Bench	pass@k (自动执行测试)	时间切片 (按发布日期筛选新题)
数学	GSM8K → MATH	→ AIME / OlympiadBench → FrontierMath	精确匹配 / 符号等价判断	时间切片 (真实赛题逐年更新) + 专家原创未公开题库
通用推理	BBH / DROP	→ MuSR (程序化生成) → ARC-AGI-2 → ARC-AGI-3 (交互式环境)	精确匹配 / 规则应用正确性 → RHAE (对标人类动作效率)	程序化生成新题 / 提高组合推理门槛 / 交互式环境 (目标与动力学皆不可记忆)

三个领域走的其实是**同一条演进路径**：自然/众包题目 → 竞赛/专家级难题 → 用"时间切片"或"程序化生成"从数据源头解决污染问题。与 Part 1 的知识类基准（本质上很难摆脱"静态数据集终将被消化"的命运）相比，垂直能力基准因为"生成+自动验证"的评分范式，更容易接入"持续产生新题目"的动态更新机制——这也是为什么 Week 13 会专门讨论"动态 Benchmark"作为对抗饱和的通用解法。

Part 3: 对齐与偏好评测

3.1 为什么知识/推理基准不够用了

Part 1、Part 2 的基准有一个共同前提：**每道题都有一个客观、唯一（或有限集合内）的正确答案**，可以用精确匹配、执行测试等自动化方式打分。但模型能力的另一大块——**对齐质量**（是否有帮助、是否诚实、是否符合人类偏好的表达风格、是否安全无害）——从根本上不满足这个前提：

- "请帮我写一封辞职信，语气要委婉但坚定" → 有无数种"好"的写法，没有唯一标准答案
- "解释一下量子纠缠给一个高中生听" → 好的解释和差的解释之间是连续的质量梯度，不是对/错二元判断
- 两个回答哪个"更有帮助" → 本质上是**偏好排序**问题，而不是"正确性判断"问题

这类任务传统上只能靠人类评审员逐条打分，但人类评审**成本高、速度慢、难以规模化**——每发布一个新模型版本都靠人工重新评一遍，在快速迭代的工程节奏下是不现实的。这就引出了对齐评测领域的核心工程思路：**用一个足够强的 LLM 来充当自动化评审员，即 LLM-as-Judge。**

3.2 LLM-as-Judge 谱系：MT-Bench → AlpacaEval(LC) → Arena-Hard

MT-Bench (Zheng et al., 2023, LMSYS) 是 LLM-as-Judge 方法论的早期代表：设计 80 道覆盖 8 个类别（写作、角色扮演、信息抽取、推理、数学、编程、STEM 知识、人文社科）的多轮对话题目，让 **GPT-4** 扮演评委，对被测模型的回答按 1-10 分打分（或者做两两对比，判断谁的回答更好）。

MT-Bench 题目示例（第一类"写作"任务，广为引用的开场题）：

第一轮: "Compose an engaging travel blog post about a recent trip to Hawaii, highlighting cultural experiences and must-see attractions."

第二轮（多轮追问，考察上下文追踪能力）: "Rewrite your previous response. Start every sentence with the letter A."

评分方式：GPT-4 作为裁判，依据预设的评分 rubric（针对不同类别有不同侵入式提示词）对每轮回答打 1-10 分；也可以两两对比裁定胜负

MT-Bench 的价值在于验证了 **"用强模型评审弱模型输出"** 这条路径是可行的——在多项研究中，GPT-4 作为裁判给出的判断与人类评审员的一致率能达到 80% 以上，接近人类评审员之间的一致率水平，这为后续大规模自动化对齐评测铺平了道路。

AlpacaEval (Li et al., 2023, Stanford) 采用了另一种设计：**成对对比 (Pairwise) 胜率** 评测——被测模型和一个固定的参考模型（早期用 text-davinci-003，后来升级为 GPT-4-Turbo）分别回答同一批问题，让 GPT-4 裁判判断哪个回答更好，统计被测模型的**胜率**作为最终得分。

Length-Controlled AlpacaEval (LC 版本, Dubois et al., 2024)：研究者发现一个系统性问题——无论回答内容质量如何，**更长的回答天然更容易在 LLM 裁判打分中获胜** (Verbosity Bias, 冗长偏差)。这意味着"提高 AlpacaEval 胜率"的一条捷径是训练模型输出更啰嗦的答案，而不是真的提升有用性。LC-AlpacaEval 的解法是引入一个统计回归模型，把"回答长度"当作混淆变量剔除后，重新计算一个"控制长度后"的胜率，从而得到更贴近真实能力排序、而不是"啰嗦程度排序"的结果。

Arena-Hard (Li et al., 2024, LMSYS) 进一步解决了 MT-Bench/AlpacaEval 的另一个问题：**固定题库的区分度不够**——很多题目对强模型和弱模型给出的分数差别不大，无法有效区分前沿模型之间的细微差距。Arena-Hard 的做法是从 Chatbot Arena 真实用户提问的海量数据中，用一套评分流程（依据"是否需要特定领域知识""是否需要复杂推理""问题是否足够具体"等 7 项标准）**自动筛选出 500 道最具区分度的高难度提示**，再用 GPT-4-Turbo 作为裁判进行成对对比打分。**Arena-Hard v2.0** (2025) 在此基础上进一步扩展：题库刷新为 500 道涵盖真实软件工程和数学问题的高难度提示，外加 250 道从 Arena 真实流量中挑选的创意写作题目；裁判模型也升级为多裁判组合（如 GPT-4.1 与 Gemini-2.5 并用，减少单一裁判模型自身偏见的影响），据官方报告与人类偏好的相关性可达 98.6%，区分度是 MT-Bench 的 3 倍以上。

3.3 Chatbot Arena：真实用户众包 + Elo/Bradley-Terry

LLM-as-Judge 系列方法虽然自动化程度高，但仍然是"用一个模型的判断代表人类偏好"——裁判模型自身的偏见会传导到评测结果中。**Chatbot Arena** (Zheng et al., 2023, UC Berkeley LMSYS) 提出了一种更彻底的方案：**跳过 LLM 裁判，直接让海量真实用户来投票。**

先交代它的"实体"身份：Chatbot Arena 不是一个数据集或评测脚本，而是一个公开网站（arena.ai，前身为 Imarena.ai 与 chat.lmsys.org），任何人打开浏览器即可免费使用。它由 UC Berkeley LMSYS/Sky Lab 团队（Vicuna 模型的同一团队）于 2023 年发起，凭借"边当产品、边当评测"的双重身份迅速成为事实上的行业标准榜单：用户免费体验各大厂商的最新模型（包括大量需付费订阅的模型），其投票行为则被汇总进公开排行榜——这解释了它为何能长期维持足够大的真实流量。2025 年团队从伯克利独立公司化（种子轮融资 1 亿美元），**2026 年 1 月品牌正式更名为 Arena**，此时平台累计约 700 万次盲测投票、覆盖 360+ 模型。网站提供三种交互模式：**Battle**（系统随机抽取两个匿名模型对战，这是计入排行榜的投票来源）、**Side-by-Side**（用户自选两个具名模型对比）与 **Direct Chat**（与单一模型直接对话）——后两者是体验功能。

投票如何变成排名：在 Battle 模式中，用户输入任意提示词，两个匿名模型分别生成回答（身份隐藏以避免品牌偏见），用户投票选出更好的一个（或判平局）。海量盲测投票积累后，系统用类似国际象棋 Elo 评分系统的统计模型为每个模型计算一个可比较的分数并排名（Elo 到 Bradley-Terry 模型演进的数学原理见附录 A.4）。

Arena 家族：文本对战之外，平台已扩展为覆盖多种能力域的榜单家族——Vision Arena（多模态理解）、Text-to-Image Arena（文生图）、WebDev Arena（网站/前端开发）、Copilot Arena（代码补全）、Search Arena（联网搜索产品对比）等，盲测投票 + 统计排名的方法论在各域间复用。

为什么被认为是当前最可信的榜单：

1. **动态性：**新模型随时可以加入测试，不存在"静态数据集过时"的问题——这是相对 Part 1、Part 2 所有基准的根本性差异
2. **真实分布：**提问来自真实用户的真实使用需求，不是研究者构造出来、可能脱离实际场景的题目
3. **难以针对性刷题：**因为没有固定题库，模型无法靠"背答案"提升分数

局限性也同样真实：

（1）无法针对性优化的说法并不绝对——虽然没有固定题库，但模型仍然可能被训练成"讨好 Arena 场景下典型用户的答题风格"（如偏好使用 Markdown 列表、加粗、恰到好处的长度），这是一种更隐蔽的 Goodhart 化，Chatbot Arena 团队在 2024 年底为此专门推出了 **Style Control**（风格控制）机制——用统计模型剔除回答长度、Markdown 格式密度等风格因素的影响后重新计算排名，这个功能现已内置到官方榜单中，用户可以随时切换"原始排名"和"风格控制后排名"对比查看；

(2) 众包评测需要持续的用户流量支撑才能保证统计显著性，运营成本不低；

(3) 真实用户的偏好本身也有偏差——普通用户未必总能准确判断哪个答案在专业性、事实准确性上更好，Arena 分数更接近"大众好感度"而非"专家质量评估"，这也是为什么 Arena-Hard (3.2 节) 要专门从 Arena 流量中筛出"区分度高的难题"作为补充，而不是完全替代 Arena 本身；

(4) **厂商信任问题**——排行榜"同版本同分"的前提（线上评测的模型 = 厂商公开发布的模型）依赖厂商按规则出牌：2025 年 4 月的 **Llama 4 事件**中，Meta 提交参评的 Maverick 版本被证实是一个"针对对话性特殊优化的实验版"，与其公开发布的权重表现差异明显，排行结果无法迁移到用户实际可用的模型上，引发社区对 Arena 公平性的激烈讨论；LMArena 官方随后公开回应该提交不符合平台期望，并更新了模型提交与审核政策。这说明众包榜单的公信力不仅由统计方法保障，同样依赖平台治理。

3.4 局限性总览：位置/长度/风格偏差与成本

把 LLM-as-Judge 和 Chatbot Arena 的局限性汇总成一张表，能看到它们许多问题是共通的：

偏差类型	表现	典型缓解策略
位置偏差 (Position Bias)	成对比较时，裁判倾向于偏好排在特定位置（通常是先出现）的答案，与内容质量无关（概念、成因与验证实验见附录 A.5）	双向评测：A-vs-B 和 B-vs-A 各跑一次，取平均结果，消除位置带来的系统性偏移
长度偏差 (Verbosity Bias)	更长、更详细的回答容易获得更高分，即使信息密度并未真正提高	Length-Controlled 统计回归（如 LC-AlpacaEval）；Chatbot Arena 的 Style Control
风格偏差 (Style Bias)	裁判模型自身的写作风格偏好会渗透进打分（偏好 Markdown 列表、偏好特定语气），导致"讨好裁判风格"成为可被针对性优化的捷径	多裁判组合交叉验证（如 Arena-Hard v2 用 GPT-4.1 + Gemini-2.5）；风格控制统计建模
自我偏好偏差 (Self-Preference Bias)	裁判模型有时会偏爱与自己家族风格相近的回答（如 GPT 系列裁判偏爱 GPT 系列的回答风格）	使用与被测模型不同家族的裁判模型；多裁判交叉验证
裁判能力天花板	裁判模型本身的判断力限制了整个评测体系的上限——"能否用一个模型评判比自己更强的模型"是一个尚无定论的自指问题	持续升级裁判模型；结合 Chatbot Arena 等真人评测做交叉校验
评估成本	人类众包评测（Arena）需要持续的用户流量支撑；高质量 LLM 裁判调用本身也有 API 成本	用 Arena-Hard 等"高区分度精选子集"降低所需样本量

2025-2026 年的一项有趣研究方向进一步揭示了这些偏差的复杂性：在成对比较评测（尤其是需要一个"锚点模型"作为参照基准的评测方式，例如 Arena-Hard 的基准回答）中，学界发现锚点模型的选择本身会显著影响评测结果与人类偏好的相关性，且呈现"倒 U 形"关系——表现最强或最弱的模型都不适合做锚点，"中等水平"的模型反而是更好的参照

基准（我们会在 Part 4 展开这一发现）。这提示我们：LLM-as-Judge 类评测方法即使经过精心设计，仍然存在许多尚待厘清的统计学陷阱，“看到一个漂亮的胜率数字”和“这个数字真实反映了能力差距”之间，还有相当的距离需要审慎对待。

3.5 超越评测：LLM-as-Judge 作为训练基础设施

前面四节中的 LLM-as-Judge 都出现在评测语境——它是“考场里的评委”。但 LLM-as-Judge 在当今大模型技术栈里的影响远不止于此：它同时深度介入**训练**语境，扮演“训练场上的教练”。四组代表性用法：

(1) 偏好数据合成与 RLAIIF。Week 4 讲过 RLHF 依赖人类标注的偏好对训练奖励模型，但人工标注昂贵且难以规模化。Anthropic 的 **Constitutional AI** (2022) 开创了 **RLAIIF** (RL from AI Feedback) 路线——用 LLM 依据一组显式原则（“宪法”）自行评判、修正和比较输出，以 AI 反馈替代人类反馈作为偏好信号。后续 DPO/IPO 类直接偏好优化算法使用的偏好对，也大量由强 LLM 标注产生——“judge 提供标签、策略习得偏好”已成为对齐数据生产的主流范式。

(2) 训练数据的质量过滤器。指令数据合成（Self-Instruct 及其后继者）可以低成本产生海量样本，但质量参差。**AlpaGasus** (2023) 等工作的思路是用强 LLM 为每条合成数据的质量打分，仅保留高分者参与训练——实验发现精筛后的小数据集效果可以超过全量数据。在这个角色里，LLM-as-Judge 充当的是**数据管线上的过滤阀**。

(3) 自蒸馏 / 自提升回路。更进一步，judge 和生成者可以是**同一个模型**。Meta 的 **Self-Rewarding Language Models** (2024) 让模型在每轮迭代中同时产出回答并为自己的回答打分，用高分样本进行下一轮 DPO 训练，实现无需外部裁判的迭代自提升（且在多轮迭代中，模型的 judge 能力本身也在同步改进）。类似思路也见于 Llama 系列的 **rejection sampling fine-tuning**：从模型的 N 个采样中用奖励模型/judge 选出最优回答，再蒸馏回模型自身——judge 在这里是“自蒸馏”回路的选优闸门。

(4) RL 阶段的在线评委。2025 年后推理模型训练的主流范式是 **RLVR** (Reinforcement Learning with Verifiable Rewards, 见 Week 7) ——可验证任务（数学答案算对、代码单测跑通）用规则化检验器提供奖励，客观且抗刷分。但对写作、开放问答、多轮指令遵循等**不可验证**任务，不存在可编程的规则检验器，主流做法是直接接入 LLM judge 作为奖励函数；**DeepSeek-GRM** (2025) 这类“生成式奖励模型”进一步通过在推理时采样多份评分并投票来提高 judge 的可靠性。Agent 场景同理：任务完成与否往往没有程序化的 ground truth，LLM-as-Judge 是 Week 11 轨迹评估 (Trajectory Eval) 和 Agent RL (见专题《AgenticRL与Agent训练》) 奖励信号的主力来源。

双重身份带来的自指闭环。当 judge 既提供训练信号、又充当评测工具时，两种身份叠加会产生一个结构性风险：模型在训练中向着 judge 的口味优化——3.4 节的四种偏差在训练侧被放大为 reward hacking 的具体形态（答案人为变长、格式更花哨、措辞更迎合评委家族）；而评测时又由同家族的 judge 给出高分"确认"了进步。训练和评测就这样互相强化了彼此的盲点。这意味着 3.4 的偏差表不只是"评测方法论问题"：一旦 judge 接入训练回路，它的偏差直接决定模型学到什么。这也是业界持续投入 judge 校准研究（多裁判组合、风格控制、长度控制）的深层动机。

Part 4: 前沿发展速览——2026 年评测体系的最新进展

4.1 偏好评测方法论的持续修正

Part 3 提到的几类偏差并不是"发现即解决"的问题，而是一个持续被修正的研究领域：

- **Arena-Hard v2.0 的多裁判设计**：从单一裁判（GPT-4-Turbo）升级为 GPT-4.1 + Gemini-2.5 组合评审，直接针对"自我偏好偏差"和"单一裁判风格偏见"设计，这代表了业界对 LLM-as-Judge 局限性的应对已经从"接受偏差存在"转向"用系统性方法主动对冲偏差"。
- **锚点模型选择研究（2026）**：针对 Arena-Hard 这类需要固定"参照回答"进行成对比较的评测方式，学界通过对超过 85 万条成对比较数据的分析发现，选用中等水平的模型作为评测锚点，其打分结果与人类偏好的相关性反而高于用顶尖模型或弱模型做锚点——这是一个反直觉但很有工程指导意义的发现：**设计评测系统时，"用最强的模型做所有事"未必是最优解**，评审角色和被评角色对模型能力的要求可能是不同的（"锚点模型"的角色、两种失效模式与统计原理的详解见附录 A.7）。
- **风格与实质的持续张力**：学界持续在追问"Style Outweighs Substance"（风格压倒实质）这一失效模式——即使做了长度控制，裁判模型仍然可能被措辞的自信程度、结构的清晰度等更隐蔽的风格线索影响判断，这是当前 LLM-as-Judge 方法论中还未被完全解决的开放问题。

4.2 基准数据质量与污染问题的持续暴露

- **FrontierMath 数据纠错（Epoch AI, 2026-06）**：如 Part 2.2 提到，即使是专家精心设计的高难度原创题库，也在两年内发现约 42% 的题目存在表述或答案层面的问题并进行了修订。这提醒我们评测基准的可信度需要持续维护，"权威机构发布"不等于"数据永远正确"。

- **SWE-bench Pro** (Scale AI, 2025)：SWE-Bench Verified 依赖的静态历史 issue 数据同样面临"训练语料已包含真实修复方案"的污染质疑。SWE-bench Pro 作为下一代迭代，选用了 **41 个持续维护的活跃仓库**（覆盖 Python/Go/TypeScript/JavaScript 四种语言），任务设计上刻意提高了修复所需改动的规模（平均约 100+ 行代码、涉及 4 个以上文件），使任务从"定位并修复一处明显 bug"转向更接近真实工程工作量的"跨文件综合修改"，并采用标准化评测脚手架减少不同评测实现之间的差异。这与 LiveCodeBench 的"时间切片防污染"思路互补——一个从"数据新鲜度"下手，一个从"任务真实复杂度"下手。

4.3 厂商评测实践的透明度趋势

评测方法论的演进不仅发生在学术界，头部大模型厂商公开技术报告中的评测实践本身也是观察行业趋势的重要窗口：

厂商	评测实践观察
DeepSeek	DeepSeek-V4-Pro（2026-04 发布）技术报告披露了覆盖代码、数学、知识、长上下文、Agent 能力等约 16 个维度的评测结果，体现出"单一通用分数"已不足以刻画模型能力画像，头部厂商越来越倾向于按能力维度分拆汇报
Qwen	Qwen3-Coder 系列技术报告针对代码能力单独细化了多套评测（含仓库级任务、多语言代码修复），呼应了 Part 2.1 中"代码评测正从函数级走向仓库级"的趋势
Anthropic / OpenAI / Google	主流厂商的模型发布报告普遍在 Humanity's Last Exam（将在 Week 13 详细讨论）、ARC-AGI-2/3、SWE-bench 系列上同时汇报分数，反映"知识饱和基准+抗饱和高难度基准+真实任务基准"三线并行汇报正成为行业惯例

一个值得警惕的现象：随着评测越来越成为模型发布营销的一部分，网络上出现了大量自动生成、更新迅速的"排行榜聚合站点"。这类站点为了 SEO 流量会展示看起来精确到小数点的具体分数，但同一个基准、同一个模型，不同聚合站点给出的数字经常互相矛盾（例如同样查询 Humanity's Last Exam 的榜首分数，几个站点在同一时间窗口内给出的具体数值和排名就明显不一致）——这说明其中不少数据缺乏可验证的原始出处，或者统计口径

本身就不一致。作为工程师和学习者，查证评测数字时应始终追溯到官方技术报告、论文原文或基准官方仓库（如本讲义引用的 Epoch AI、LMSYS/lmarena 官方博客、arXiv 论文），而不是依赖二手聚合页面的数字。这里还有一层更容易被忽略的陷阱值得单独强调："某个模型/产品名称是否真实存在"与"某条具体分数是否准确"是两个独立的问题，不能混为一谈——前沿模型的发布节奏很快，一个陌生的名字很可能只是尚未进入你的知识范围（尤其是限制发行、未公开面向 API 开放的模型），而不能仅凭"没听过"就断定是编造；反过来，即便确认某个模型真实存在，聚合站点给它标注的具体分数依然可能不准确，仍需要交叉验证到一手来源。这本身也是评测体系可信度问题在信息生态层面的延伸，呼应了 Week 13 会讨论的"厂商透明度"话题。

✅ 本周检查点

通用能力评测：

- [] 能说出 GLUE 9 个子任务和 SuperGLUE 8 个子任务各自的任务类型
- [] 能画出 GLUE → SuperGLUE → MMLU → MMLU-Pro/BIG-Bench(Hard) 的演进链，并解释每一步升级解决了上一代的什么局限
- [] 能用 1 条具体样例解释 MMLU 的输入输出格式（57 学科、4 选项、5-shot 协议）
- [] 理解 Log-likelihood 打分与生成式匹配打分的区别，以及为什么同一模型在两种评分方式下会报出不同分数
- [] 理解 MMLU 饱和的两个纠缠原因（真实能力提升 vs 训练数据污染）以及 MMLU-Pro 的应对方式

垂直能力基准：

- [] 能说出 HumanEval / MBPP / LiveCodeBench / SWE-Bench 各自的任务粒度差异与评分方式
- [] 能推导 pass@k 的无偏估计公式并解释为什么需要"无偏估计"而不是简单的通过率
- [] 能说出 GSM8K / MATH / AIME / FrontierMath 的难度演进脉络，以及"时间切片防污染"这一思路的原理
- [] 理解 SWE-Bench Verified 相对原始 SWE-Bench 解决了什么问题（回顾 Week 11）
- [] 理解 ARC-AGI 系列"抗记忆、抗刷题"的设计哲学与其他基准的本质区别，能说出 ARC-AGI → ARC-AGI-2 → ARC-AGI-3 三代演进（静态谜题 → 抗暴力枚举 → 交互式环境）及 RHAIE 效率评分的设计意图

对齐与偏好评测：

- [] 理解为什么知识/推理类评测方式不适用于对齐能力评估
- [] 能说出 MT-Bench / AlpacaEval(LC) / Arena-Hard 三者在评测机制设计上的递进关系
- [] 理解 Chatbot Arena 相对静态基准的核心优势（动态、真实分布、难以针对性刷题）与局限（风格优化空间、运营成本、大众偏好≠专家质量）
- [] 理解 LLM-as-Judge 的至少 4 种常见偏差（位置/长度/风格/自我偏好）及其对应缓解策略
- [] 能说出 LLM-as-Judge 在训练侧的四类角色（RLAIF 偏好信号、数据质量筛选、自蒸馏选优、RL 在线评委），以及训练与评测共用 judge 的自指闭环风险

本周末覆盖、留待 **Week 13** 深入的内容：多模态与长上下文评测

（MMMUI/RULER/LongBench-v2）、Agent 与推理评测深入（结合 Week 11 基础的 Trajectory Eval 系统化）、Humanity's Last Exam、自定义评估设计方法论、污染检测方法（N-gram/Min-K%/Canary Strings）、Goodhart's Law 与"评测即优化目标"的风险。

附录

A.1 MMLU 两种评分方式的完整对比实现

关联正文：**1.4 节** → 评分方式的分裂

以下伪代码完整展示同一道 MMLU 题目在两种评分方式下可能产生不同判定结果的具体机制，帮助建立"评分框架实现细节会实际影响报出的分数"这一工程直觉。

```
# 假设模型对某道 4 选项题的真实内在偏好是选项 B（对数似然最高）
# 但模型的指令遵循能力不完美，生成式回答时输出格式不规范

# ----- 方式一：Log-likelihood 打分（需要访问模型内部 logits） -----
def loglikelihood_scoring(model, question, choices):
    scores = {}
    for label, choice_text in choices.items():
        prompt = f"{question}\nAnswer: {choice_text}"
        # 计算模型对该选项文本的对数似然（不要求模型"生成"任何内容）
        scores[label] = model.compute_logprob(prompt)
```

```

return max(scores, key=scores.get) # 假设返回 "B", 与真实答案一致 → 判对

# ----- 方式二：生成式匹配（依赖模型输出格式 + 正则抽取规则） -----
def generative_scoring(model, question, choices):
    prompt = f"{question}\n{format_choices(choices)}\nAnswer with the letter only."
    response = model.generate(prompt)
    # 若模型输出 "I believe the correct answer is option B because..."
    # 而抽取规则只匹配严格的 "[A-D]" 格式，则会抽取失败 → 判错 (False Negative)
    extracted = re.match(r"^[A-D]$", response.strip())
    return extracted.group(0) if extracted else None # 返回 None → 判定为错误

# 同一个模型、同一道题，两种方式可能得出不同的对错判定，
# 这正是不同评测框架报出的同名基准分数经常无法直接横向比较的根源之一。

```

A.2 pass@k 无偏估计公式推导

关联正文：2.1 节 → HumanEval 评分指标

问题：给定一道编程题，模型采样生成 n 个解，其中 c 个通过了测试。如果只允许使用其中 k 个样本 ($k \leq n$)，"这 k 个样本中至少有一个通过"的概率是多少？

一个朴素但有偏的估计是直接从 n 个样本中截取前 k 个来看是否有通过的——但这样做的结果会因为具体截取的是哪 k 个样本而产生随机波动，方差很大。正确做法是计算**期望概率**：从 n 个样本中随机抽取 k 个（不放回），至少有一个是通过样本的概率。

利用其补事件（"抽出的 k 个全部来自失败样本"）更容易计算：

$$\text{pass@k} = \mathbb{E}_{\text{Problems}} \left[1 - \frac{\binom{n-c}{k}}{\binom{n}{k}} \right]$$

其中 $\binom{n-c}{k}$ 表示"从 $n - c$ 个失败样本中选出 k 个（即全部抽到失败样本）"的组合数， $\binom{n}{k}$ 是从全部 n 个样本中选 k 个的组合数，两者相除就是" k 个样本全部失败"的概率，1 减去它即为"至少一个成功"的概率。对每道题目算出这个值后，再对整个题库取平均，就得到整体的 pass@k 分数。

工程实践中的典型取值： $n = 200$ （每题采样 200 次以获得稳定统计量），报告 pass@1、pass@10、pass@100 等不同 k 值下的结果，分别对应"单次尝试成功率"给 10 次机会的成功率"等不同工程场景的参考意义。

A.3 GLUE / SuperGLUE 任务全景速查（含 Train/Dev/Test 精确数据量）

关联正文：1.1 节、1.2 节

基准	任务	指标	Train	Dev	Test
GLUE	CoLA	Matthews 相关系数	8,551	1,043	1,063
GLUE	SST-2	准确率	67,349	872	1,821
GLUE	MRPC	F1 / 准确率	3,668	408	1,725
GLUE	STS-B	皮尔逊/斯皮尔曼相关系数	5,749	1,500	1,379
GLUE	QQP	F1 / 准确率	363,870	40,431	390,965
GLUE	MNLI	准确率	392,702	~9.8k(matched)+~9.8k(mismatched)	~9.8k(matched)+~9.8k(mismatched)
GLUE	QNLI	准确率	104,743	5,463	5,463
GLUE	RTE	准确率	2,490	277	3,000
GLUE	WNLI	准确率	635	71	146
SuperGLUE	BoolQ	准确率	9,427	3,270	3,245
SuperGLUE	CB	准确率/F1	250	56	250
SuperGLUE	COPA	准确率	400	100	500
SuperGLUE	MultiRC	F1a / EM	27,243	4,848	9,693
SuperGLUE	WiC	准确率	5,428	638	1,400
SuperGLUE	WSC	准确率	554	104	146
SuperGLUE	RTE	准确率	复用 GLUE RTE (2,490 / 277 / 3,000)		
SuperGLUE	ReCoRD	F1 / EM	100,730	10,000	10,000

几个容易读错单位的细节：

- **QQP 的 test 集异常大**（39 万，远超 train 的 3.6 万的合理测试集比例）：GLUE 官方为了防止参赛者通过反复提交、逼近测试集标签进行"探测式过拟合"，在真正的测试样本中混入了大量不计分的干扰样本，此后从公开渠道拿到的 QQP test 集标签也并不完整——这是**评测基准设计层面主动做的"反作弊"工程手段**，与 Part 2 讨论的"污染检测"呼应，但方向相反：这里不是检测污染，而是从测试集设计上主动增加"猜测/记忆测试集"的难度。
- **MultiRC 的计数单位是"候选答案样本数"而不是"问题数"**：MultiRC 每道阅读理解题都配有多个候选答案，模型需要对每个候选答案单独做二分类判断（是否为正确答案之一），因此表中 27,243 指的是"问题-候选答案对"的总数，实际的段落数和问题数远小于这个数字（约几百个段落、数千个问题）。
- **MNLI 的 dev/test 集拆成 matched（与训练数据领域一致）和 mismatched（跨领域）两份**：这是刻意的设计——用 mismatched 集单独检验模型的领域泛化能力，而不是只看同分布下的准确率。
- **ReCoRD 的 10 万+ 查询覆盖约 8 万个不同的新闻/维基百科段落**：属于 SuperGLUE 中规模最大的任务，任务形式是"完形填空式"阅读理解——给定一段新闻和一个抠掉实体的问题句，从段落中已出现的实体里选出正确答案。
- **CB / COPA / WSC 这三个任务的数据规模明显小于其他任务**（几百到一千量级）：这正是 Part 1.2 提到的"人类基线和模型差距被重新拉大"的另一面代价——难度更高、更依赖常识推理的任务，往往也更大规模众包收集，SuperGLUE 在"任务难度"和"数据规模"之间做了明显的取舍。

A.4 Elo 到 Bradley-Terry：Chatbot Arena 排名算法的数学原理

关联正文：3.3 节 → Chatbot Arena 机制

经典 Elo 评分（源自国际象棋）是一种**在线增量更新算法**：每完成一场对局，就根据"预期胜率"与"实际结果"的差异，用固定学习率更新双方分数：

$$R'_A = R_A + K \cdot (S_A - E_A), \quad E_A = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

其中 E_A 是根据当前分数差算出的 A 预期胜率， S_A 是实际结果（胜=1，负=0，平=0.5）， K 是学习率常数。这种增量更新方式简单高效，但有一个统计学缺陷：**结果依赖于对局发生的顺序**——同样一批对局按不同顺序输入，算出的最终分数可能不同，这在需要严格排名的场景下是不理想的。

Chatbot Arena 后续采用的是**离线拟合 Bradley-Terry 模型**：把每个模型的"实力"看作一个待估参数 θ_i ，两模型对战时 A 胜过 B 的概率建模为

$$P(A \succ B) = \frac{e^{\theta_A}}{e^{\theta_A} + e^{\theta_B}}$$

再用**全部**已收集到的成对投票数据，通过最大似然估计（等价于对这个式子做逻辑回归）一次性求解出所有模型的 θ_i ，而不是按对局顺序逐步更新。这样得到的排名**与数据到来的顺序无关**，统计上更稳健，也更容易加入置信区间估计（通过 Bootstrap 重采样得到每个模型分数的置信区间，避免"分数差 1 分"被误读为"能力有显著差距"）。这也是为什么 Chatbot Arena 官方榜单上，模型排名旁边总会附带一个分数区间，而不是一个单点数字。

A.5 位置偏差详解：概念、成因与最小化验证实验

关联正文：[3.4 节](#) → 位置偏差

什么是位置偏差

LLM-as-Judge 的典型用法是成对比较：把两个回答并排交给裁判，请它判断哪个更好

— —

问题：xxx
回答 1：【被测模型 A 的回答】
回答 2：【被测模型 B 的回答】
请判断哪个回答更好。

位置偏差（Position Bias）指：裁判的判决会系统性地偏袒占据某个位置的回答（多数裁判偏袒排在前面的回答），与回答的实际内容质量无关。它不是"裁判按顺序依次评分、被前者干扰"，而是**恒定的位置性偏袒**——换一对全新内容，它仍偏心同一个位置；把同一对内容顺序对调，它的判决可能跟着翻转。

如何判定一个裁判是否存在位置偏差：对同一对回答，正反顺序各评一次——

输入顺序	理想裁判（无偏差）	存在位置偏差的裁判
[A 在前, B 在后]	判 A 更好	判"位置 1"（即 A）更好
[B 在前, A 在后]	仍判 A 更好（位置标签变了，但指向同一实体）	仍判"位置 1"（即 B）更好

两次判决指向同一实体（只是位置标签互换），说明裁判在比较内容；两次都判"排在前面的赢"，说明判决被位置信号主导。

成因直觉：自回归生成中，先出现的回答为后续 token 的生成设定了参考框架（先读到的内容塑造理解后续内容的语境），产生"先入为主"的锁；其次训练语料（尤其是评测类文本）本身存在"先列更优选项"的分布习惯，模型从中继承了"靠前的更可能正确"的先验。需要注意，偏差方向（偏好靠前还是靠后）因裁判模型而异，只能通过实测确定。

为什么必须显式消偏：位置偏差是有固定方向的**系统性误差**，而非随机噪声——随机噪声可靠"多跑题自然平均"削弱，系统性误差不会随样本量增加而自动消失，它会一致性地把排名拉向同一方向。因此必须靠"正向+反向各评一次、聚合取平均"在实验设计层面显式对冲，这也是 MT-Bench 论文系统报告该现象后双向评测成为成对比较评测标配的原因。

最小化验证实验

有了上面的判定逻辑，验证实验本身非常轻量——几乎不需要额外基础设施、任何人都能复现：

```
# 最小化位置偏差验证实验（伪代码，可直接套用任意支持 Chat 接口的模型 API）

def judge_pairwise(question, response_first, response_second,
judge_model):
    prompt = f"""问题: {question}
    回答 1: {response_first}
    回答 2: {response_second}
    请判断哪个回答更好，只输出 "1" 或 "2"。"""
    return judge_model.generate(prompt).strip()

# 关键步骤：对同一对（回答A，回答B），正反顺序各跑一次
result_AB = judge_pairwise(question, response_A, response_B, judge_model)
# A在前
result_BA = judge_pairwise(question, response_B, response_A, judge_model)
# B在前
```

```
# 如果不存在位置偏差: result_AB 应该判定 A 更好, result_BA 也应该判定 A 更好
# (即两次结果指向同一个"获胜者", 只是数字标签因顺序不同而互换)
# 如果两次结果出现矛盾 (如都判定"排在前面的那个更好"),
# 就实测证实了裁判模型存在位置偏差, 需要用双向平均的方式消偏
```

把这个实验在几十道不同类型的问题上重复运行, 统计"两次结果矛盾"的比例, 就能得到一个具体的位置偏差强度估计值——这正是 Part 3.4 提到的"双向评测"缓解策略在工程上的最小可行实现。

A.6 AIME"时间切片"设计的三个代价：跨年可比性、统计噪声与饱和加速

关联正文：2.2 节 → "饱和与升级"中的 AIME

问题：AIME 靠"每年出新题"天然获得抗污染能力——题目在模型训练 cutoff 之后才发布, 不可能被背进训练数据, 这是它作为推理模型基准的核心优势。但这种"时间切片防污染"设计并非零成本, 代价体现在以下三个方面。

代价一：纵向可比性失效，但横向可比性保留

题池跟着年份轮转意味着 AIME 2024 的分数与 AIME 2025 的分数测的是**两套不同的题**, 二者之间不存在共同参照系, 严格的跨年份（纵向）比较因此失效。但值得强调的是, **横向比较并未失效**——同一年内的各家前沿模型测的是同一个试题集, 例如各家报告的 AIME 2025 分数仍然构成严格有效的横截面排名。

换句话说, "时间切片"把评测比较的有效窗口压缩到了大约一年这个量级。一个务实的解读是：在模型能力以季度为单位演进的当下, 跨年度的精确纵向对比本就已丧失大部分实践意义——"时间切片"只是把这一事实显式化了, 真正受损的不是评测的严谨性, 而是"跨年代际对比"这一叙事习惯。

代价二：不同年份难度分布波动——比"题不一样"更隐蔽的问题

即使承认题不同, 还有一层更微妙的干扰：**不同年份的 AIME 难度分布本身就有波动**。出题团队的风格、当年题目的结构（计算密集型 vs 技巧密集型）都会带来偏倚。这意味着"AIME 2024 考 90% vs AIME 2025 考 85%"不能直接读成"能力退步 5%"——这 5 个百分点里有多少来自难度变化, 无法从分数本身分离。

正因为这一点，像 MathArena 这类滚动评测框架在设计上刻意保证一点：**用同一批最新竞赛题同时评测所有新发布的模型**，强制保持分母一致，而不是允许各家自行挑选有利的年份报告。

代价三：题量太小，单次评测统计噪声大

AIME 每年只有 30 题（AIME I、AIME II 两卷各 15 题）。在 30 个样本上，一道题的运气波动就是约 3.3 个百分点的分数差，三道题的偏差即可造成 10 个百分点的表观差异。因此前沿模型报告 AIME 分数时几乎普遍采用 **avg@k**（对每题独立采样 k 次取平均正确率，常见 $k = 16、64$ ）而非单次 **pass@1**。这与 Part 2.1 代码基准中 **pass@k** 面临的统计问题一脉相承——小题量基准天然对单次评测敏感，多次采样平均是必要而非可选的修正。

副产品：AIME 正在快速饱和

推理模型的演进速度大幅压缩了 AIME 的生命周期：自 2024 年底被大规模采用为推理模型标准基准以来，第一梯队模型在 2025 年下半年已进入 95%+ 区间，区分度正在快速消失。这延续了正文 2.2 节的演进链逻辑：

GSM8K（小学应用题，2021）→ MATH（竞赛题，2021）→ AIME（奥赛入门，历年赛事）
→ FrontierMath（研究级，2024）→ HMMT / IMO 级（2025+）

一个基准保持"有区分度的前沿基准"定位通常只有两三年。这并非 AIME 独有的命运，而是评测体系的根本特征：**只要模型能力增速快于基准难度储备，基准就必须不断向下一代迭代**——Part 1（MMLU 系列）和 Part 2（代码/数学基准）反复出现同一模式，原因均在于此。

A.7 锚点模型的"倒 U 形"：为什么中等水平模型是最好的参照物

关联正文：[4.1 节](#) → [锚点模型选择研究](#)；[3.4 节](#)末段

问题：在 Arena-Hard 这类依据"参照回答"进行成对比较的评测中，生成参照回答的模型（锚点模型，anchor/baseline）该选多强？直觉答案是"越强越严格"，但研究发现锚点模型能力与评测结果同人类偏好的相关性呈"倒 U 形"——**中等水平模型反而最优**。要理解这个反直觉结论，需要先厘清锚点模型扮演的角色。

锚点模型的角色：不是裁判，是参照物

回顾 Arena-Hard 的打分机制：对每道难题，被测模型 A 生成一份回答，固定的锚点模型 B 生成一份参照回答，两者送交 LLM 裁判进行成对比较；**模型 A 的最终得分 = 它在题库上赢过锚点模型的胜率**。排行榜上所有分数都是"相对同一参照物的胜率"——借助攀岩馆的类比：所有选手爬的都是同一条参照线，报告的成绩是"比参照线多爬了几米"。

注意这里存在两个不同的角色：****裁判 (judge) ****负责读两个回答并投票；****锚点 (anchor) ****只负责产出参照回答。后文的结论只针对锚点的选择，不涉及裁判的选择。

失效模式一：锚点是顶尖模型 → "地板效应"

所有被测模型都输给它，胜率被压缩在极低区间（如 5%–15%）。排名问题退化为"比谁输得不那么惨"，顶尖被测模型之间的细微差异无法传导进分数。此外，judge 面对"锚点明显更好"的比较时，判决几乎完全被锚点的绝对质量决定，比较信号携带关于被测模型的信息极少。

失效模式二：锚点是很弱的模型 → "天花板效应"

所有被测模型都碾压它，胜率被压缩在极高区间（如 90%–99%），区分度同样丢失。更糟的是，"赢一个明显更弱的回答"对 judge 是个粗糙任务——内容、结构、完整性全方位碾压时，judge 无需做任何精细的质量权衡就能轻松判胜，判决结果也就不携带多少有辨识度的信息。

为什么中等水平锚点最优

- 区分度最大化**：中等水平锚点大致位于被测模型能力分布的中间位置，各模型的胜率自然散布在较宽区间（如 20%–80%），细微的能力差距能映射为可测量的胜率差。
- 比较任务变得更精细**：大量"两个质量相近回答"的比较，迫使 judge 进行细粒度判断（内容是否正确、是否答到点上），而不是被长度、格式等表面差异主导——这类判决更贴近人类评审员的实际判断模式。
- 统计学原理**：Bradley-Terry 这类成对比较模型中，单次比较对参数估计贡献的信息量在双方实力接近（胜率接近 50%）时达到峰值；锚点是所有模型的"公共对手"，公共对手越强或越弱，所有配对的信息量都随之下降。

生活类比：想通过"与同一个公共对手下棋"为一群棋手排名时，选棋王（大家都输，只比输多惨）或选新手（大家都赢，只比赢多快）都不是好参照；选一个水平居中的对手，每盘胜负对人群能力分布的刻画才最细腻。

两个易混淆点的澄清

- 该结论与"裁判应该用最强的模型"并不矛盾：**裁判是"打分的人"**，**判断力越强越好**；**锚点是"被比的靶子"**，**作用是可区分化，强度居中信息量最大**。这正是"评审角色与被评角色对模型能力的要求不同"的具体含义。
- 该发现的工程推论值得注意：Arena-Hard 长期使用的锚点是 GPT-4-0314——它在 2024 年属强模型，随着被测模型整体水平提升，其相对位置自然滑向"中等"，无意中恰好满足倒 U 形的研究结论；但如果题库和锚点长期不更新（被测模型整体把它们远远地甩在后面），锚点会滑向失效模式二（天花板效应），这是静态参照物设计的内在老化问题。