

Week 14 讲义：业界架构演进与三巨头最新架构解析

本周主题：Phase 7 启动。第一部分快过 2017-2024 的架构演进谱系（原理在 Week 1-2 已详讲）；主体部分深入解析 2026 年三巨头的最新架构——**DeepSeek V4/V4.1**、**Qwen3.8-Flash-Next**、**Kimi K3/K2.8**，收官阶段建立"厂商谱系"的全局视野。

核心目标

学完本周，你应该能够：

1. **演进视角**：能画出主流模型的设计选择对比表，理解演进背后的"两股绳"（能力 vs 效率）如何驱动每个决策
2. **DeepSeek**：理解 V4 如何把 1M 上下文变成日常可用（mHC 残差重构 + CSA/HCA 序列维压缩 + 训练栈工程），以及 V4.1 非对称编解码的原理
3. **Qwen**：理解 3.8-Flash-Next 的五层解耦设计，特别是 51B N-gram 显式查表记忆的工程意义
4. **Kimi**：理解 KDA 的逐维遗忘机制与 AttnRes 的深度维选择性检索，以及两者与 mHC 的哲学对比
5. **横向综合**：能总结 2026 年三巨头架构收敛的五大主题，并解释为什么"Transformer 标准组件"本身正在被重写

知识图谱

业界架构演进（快过）

- └─ 2017-2024 谱系收敛：GPT-3 → LLaMA → Llama-2/3 → Qwen/Mixtral
- └─ 两股绳：能力（深/宽/长） vs 效率（计算/显存/通信）
- └─ 2025-2026 架构革命：五条战线同时开打

↓

三巨头深度解析

- └─ DeepSeek V4/V4.1（主线：1M 上下文日用化）

- | | — mHC: 残差连接 → 流形约束超连接 (深度维)
- | | — CSA+HCA: 序列维混合压缩 (KV 条数 n 的压缩)
- | | — 训练栈: Muon / FP4 QAT / Anticipatory Routing
- | | — V4.1 Flash: 非对称编解码 (输入 8B / 输出 16B)
- | — Qwen3.8-Flash-Next (主线: 容量与计算五层解耦)
- | | — GDN+QSA 3:1 混合注意力 (衔接 W8)
- | | — 51B N-gram Embedding: 显式查表记忆 (衔接 W9)
- | | — Gated Residual + Muon: 训练稳定性
- | — Kimi K3/K2.8 (主线: 信息流动的时间维与深度维)
- | | — KDA: 标量遗忘 → 逐维对角遗忘 (时间维)
- | | — AttnRes: 固定残差 → 层间注意力 (深度维)
- | | — 896选16 超稀疏 MoE + LatentMoE/Quantile Balancing

↓

横向综合: 收敛五大主题

序列维压缩 / 深度维重构 / 超稀疏 MoE / 显式记忆回归 / 训练稳定性工程

与前几周的衔接: 本周是"架构线"的终点站——Week 1-2 打的架构地基

(RoPE/RMSNorm/SwiGLU/MoE)、Week 6 的推理工程 (KV Cache/prefill-decode 不对称/量化)、Week 8 的多模态骨干 (Qwen3.5-Omni 的 Hybrid MoE+GDN)、Week 9 的记忆系统、Week 13 的长上下文评测 (RULER 有效长度), 全部在本周汇合。阅读时请把这些锚点放在手边。

Part 1: 业界架构演进概览 (快过)

本部分策略: 设计原理 (RMSNorm 为什么好、RoPE 怎么旋转、MoE 怎么路由) 在 Week 1-2 已经详讲, 此处不重复展开, 只做两件事: (1) 一张表收拢谱系; (2) 提炼驱动演进的"两股绳"与 2025-2026 的革命格局, 为三家解析做铺垫。

1.1 谱系收敛：2017-2024

模型	时间	Norm	激活	位置编码	注意力	FFN	关键贡献
GPT-3	2020-06	Post-LN	GELU	可学习绝对	MHA	Dense	证明 Scaling Law 可行（见 W1）
LLaMA	2023-02	Pre-RMSNorm	SwiGLU	RoPE	MHA	Dense	开源谱系的"标准件"起点（见 W1）
Llama-2 70B	2023-07	同上	SwiGLU	RoPE	GQA	Dense	GQA 进入主流（KV Cache 压缩 8x）
Mixtral 8x7B	2023-12	同上	SwiGLU	RoPE	GQA	MoE	开源 MoE 旗手（见 W2）
Llama-3	2024-04	同上	SwiGLU	RoPE	GQA	Dense	8k→128k 长上下文工程化
Qwen3	2025-04	同上	SwiGLU	RoPE	GQA	MoE	Dense/MoE 双线 + 思考模式
DeepSeek- ek-	2024-05/12	同上	SwiGLU	解耦 RoPE	MLA	DeepSeekMoE	MLA + Sigmoid

模型	时间	Norm	激活	位置编码	注意力	FFN	关键贡献
V2/V3							路由 (见 W2)

读这张表的方法：从 GPT-3 到 LLaMA 的三处替换（Pre-RMSNorm/SwiGLU/RoPE）不是"更好"这么简单——三者共同把**训练稳定性**和**外推性**提到工程可用的水平（Pre-LN 去掉 warmup 依赖，RoPE 支持长度外推，见 W1）。LLaMA 之后，开源界的"标准件"十年未变，变化都发生在注意力头组织（MHA→GQA→MLA）和 FFN 稀疏化（Dense→MoE）两条支线上。

1.2 演进的两股绳

回头看每一步替换，背后都是同一对张力的不同侧面：

绳 1：能力（把模型做得更强）

- 深：层数增加 → 表达力增强，但训练不稳定（残差流的信号控制问题）
- 宽：参数量增加 → 知识容量增加，但成本线性上升
- 长：上下文扩展 → 应用价值增加，但 $O(n^2)$ 计算与 KV Cache 线性膨胀

绳 2：效率（把能力做得便宜）

- 计算效率：MoE 激活解耦、线性注意力、稀疏注意力
- 显存效率：GQA/MLA 压 KV、量化（BF16→FP8→FP4，见 W6）
- 训练效率：Muon 优化器、FP8/FP4 训练、并行策略（见 W2）

关键观察：2024 年之前，绳 2 的创新大多发生在"组件级替换"（换个激活函数、换个注意力变体），Transformer 的骨架——**残差连接 + 注意力层 + FFN 层的堆叠范式**——从未被动摇。而 2025-2026 年的革命不同：**骨架本身被重写了**。

1.3 2025-2026：五条战线同时开打

这是本周主体部分的地图。三巨头的架构创新可以放进一张"五条战线"矩阵：

战线	旧范式	新方向	主要玩家
注意力：序列维	全注意力 $O(n^2)$ 、KV 随 n 膨胀	线性注意力 + 稀疏检索混合（GDN/QSA、CSA/HCA、KDA）	三家全部
残差：深度维	固定残差求和（ResNet, 2015）	流形约束多路残差（mHC）、层间注意力（AttnRes）、门控残差（GR）	DeepSeek/Kimi/Qwen
FFN：稀疏度	Top-8 MoE（激活比 ~1/7）	超稀疏 MoE（896选16, 56:1）+ 负载均衡新解法	Kimi/Qwen
记忆：表示形态	全部参数化（隐式记忆）	显式查表记忆回归（51B N-gram Embedding）	Qwen
训练：稳定性	AdamW + BF16	Muon + FP8/FP4 QAT + 路由级稳定性工程	DeepSeek/Qwen/Kimi

为什么是现在？三个外部条件同时成熟：

1. **1M 上下文成为产品标配**（Week 13 看到的评测侧需求倒逼架构侧）：1M token 下，标准注意力的 KV Cache 按旧范式根本放不下——RULER 揭示的"声称长度 vs 有效长度"裂缝，架构必须正面回应；
2. **模型深度跨过临界点**：百层以上的深层网络，固定残差求和的信号稀释/发散问题从"理论隐患"变成"工程现实"；
3. **推理成本成为竞争主战场**：Agent 时代（Phase 5）的 token 消耗量是 Chatbot 时代的百倍，效率架构直接决定商业模型。

带着这张地图，我们逐一进入三家。

Part 2: DeepSeek V4/V4.1 深度解析

2.1 主线：把 1M 上下文变成日常可用

DeepSeek-V4 技术报告（2026-04-24）的核心叙事不是"又变强了"，而是一个工程命题：**要把 1M context 从"顶到 1M 的能力演示"变成"推理服务实际可承担的日常配置"**。这需要架构、infra、训练、后训练全链条协同，最终把 1M token 场景下的**推理 FLOPs 压到 V3.2 的 27%、KV Cache 压到 10%**。

V4 延续了 DeepSeekMoE + MTP（Multi-Token Prediction，多 token 预测投机解码模块）的骨架，但在三个关键位置做了替换：

位置	V3 时代	V4 时代
残差连接	标准残差	mHC（流形约束超连接）
注意力	MLA	CSA + HCA 混合注意力
优化器	Adam（FP8 混合精度）	Muon（部分替代）+ FP4 QAT

下面逐一展开。MLA 的原理本身在本课程已完整覆盖（数学推导、解耦 RoPE、矩阵吸收见 [专题学习/MLA专题讲义.md](#)，W2 亦有速览），本节聚焦"V4 为什么要动它"。

2.2 mHC：残差连接的重构

2.2.1 问题：残差连接的"恒等映射"红利正在耗尽

先回顾我们熟悉的世界（W1）：Transformer 的每一层做的是

$$h_{l+1} = h_l + F_l(h_l)$$

这个形式（ResNet, 2015）的伟大之处在于**恒等映射性质**：当 $F_l \rightarrow 0$ 时，网络自动退化为恒等函数，梯度可以通过"加法捷径"无损回传。这是深层网络可训练的根本原因——训练初期的网络接近恒等，信息流和梯度流都是"保真"的。

问题出在两个新需求上：

1. **HC 的尝试与代价。**Hyper-Connections (HC) 把单条残差流扩展为多条（扩展宽度），并在层间做多样化的线性混合——性能确实涨了，但**多样化连接破坏了恒等映射性质**：信号在多层混合矩阵间传播时，范数可能无界放大或衰减，导致训练不稳定，且额外的混合矩阵带来内存访问开销。深层网络（100+ 层）下这个问题是致命的。
2. **V4 的深度。**1M 上下文的模型需要非常深的网络（时间维压缩靠层数换取），训练稳定性从"锦上添花"变成"能不能训出来"。

2.2.2 mHC 的核心思想：把残差映射约束到双随机矩阵流形

mHC (Manifold-Constrained Hyper-Connections, arXiv 2512.24880) 的解法极为优雅：保留 HC 的多路残差流和可学习连接，但强制每层的混合矩阵落在"双随机矩阵流形"上。

双随机矩阵：行和、列和都等于 1 的非负矩阵。它有两个关键代数性质：

- **闭包性**：两个双随机矩阵相乘还是双随机矩阵。所以无论堆多少层，整体信号传播的"总量守恒"不变；
- **Birkhoff-von Neumann 定理**：任何双随机矩阵都可以表示为**置换矩阵的凸组合**。直觉：用双随机矩阵混合特征 = 只做"平均 + 重排"，**既不放大也不缩小信号**。

一句话直觉：mHC 层间的信息流动像水流经一组管道——HC 的无约束矩阵是"管径随机变化的管道"（水量会涨落），mHC 的双随机矩阵是"总量守恒的分流器"（流出去的水永远等于流进来的水）。恒等映射的"保真"性质由此被数学地锁死。

实现：用 **Sinkhorn-Knopp 算法**（一个快速把任意非负矩阵迭代投影成双随机矩阵的经典算法）在每次前向时做投影，配合 Sigmoid 保证非负性。据报道，mHC 在基础设施级优化后计算开销几乎可忽略。

2.2.3 与已知知识的连接

- 与 **W1 Pre-LN** 的呼应：Pre-LN 是通过"归一化位置"换训练稳定，mHC 是通过"残差结构约束"换训练稳定——同一个问题（深层信号控制）在不同时代的两种解法，前者已经是标准件，后者正在成为新标准件；
- 与 **Kimi AttnRes** (Part 4) 的对比：两家都动了残差连接，但方向相反——mHC 做**减法**（约束连接空间，牺牲表达自由度换稳定性），AttnRes 做**加法**（让层间连接变成注意力，扩大表达自由度）。这个对比是本周最有意思的思考题之一，我们在 4.5 节展开。

2.3 CSA + HCA：序列维的混合压缩

2.3.1 问题：MLA 压了宽度，没压条数

回顾 MLA 的压缩逻辑（详见专题讲义）：MLA 把每个 token 的 KV 压缩成低维潜向量 c^{KV} （512 维替代 16384×2 维），压的是每条 KV 的“宽度”。但 KV 的条数——即序列长度 n ——一点没变。

在 128K 时代这不是问题；到了 1M 时代：

- KV Cache 总量 = 条数 $\times$ 宽度。MLA 把宽度压到 $1/32$ ，但 1M 条数本身就把总量拉回来了；
- 注意力计算 $O(n^2)$ ：MLA 对计算复杂度没有任何改善。

结论：想做 1M，必须把 n 也压下来。这就是 V4 混合注意力的使命——用两种压缩强度的注意力交替布置，分别对付计算和显存。

2.3.2 CSA：压缩 + 稀疏（对付计算）

CSA (Compressed Sparse Attention) 两步走：

1. 块合并：每 $m = 4$ 个 token 的 KV 合并成 1 条压缩 KV $\rightarrow$ 序列长度从 n 变 $n/4$ 。直觉：相邻 4 个 token 的注意力键值通常高度相关，合并近似无损；
2. 稀疏选择：在合并后的 KV 上，每个 query 只挑 top- k 条做点积（继承 V3.2 的 DSA/DeepSeek Sparse Attention 索引机制）。最终每个 query 只读 k 条 KV。

效果：注意力计算从“每 query 读 n 条”降到“每 query 读 k 条” ($k \ll n$)，计算量对序列长度近似线性。

代价：4 倍合并 + 稀疏选择是有损的——精确 recall（逐字复述、精确检索类任务）会受损。

2.3.3 HCA：重度压缩 + 稠密（对付显存）

HCA (Heavily Compressed Attention) 走另一个极端：

1. 重度块合并：每 $m' = 128$ 个 token 的 KV 合并成 1 条 $\rightarrow$ 序列长度从 n 变 $n/128$ ；

2. 不做稀疏选择：合并后的短序列上做**全量 dense attention**。

效果：KV Cache 直接缩小约 128 倍（这是"KV 降至 10%"的主力），显存问题解决。

代价：128 合一的压缩必然丢失细粒度信息——HCA 层"记得大意，记不住细节"。

2.3.4 混合编排：两种损失互补

V4 的做法是让 **CSA** 和 **HCA** 在不同层上交替出现：

- CSA 层负责"精读"（压缩少 + 稀疏挑选，保关键细节的精确 recall）；
- HCA 层负责"泛读"（重度压缩 + 稠密，保全局轮廓的低成本记忆）。

这与 Qwen 的 GDN+QSA 混合（Part 3）、人脑的"细节记忆 + 要旨记忆"双系统是同构的设计哲学：单一注意力机制无法同时满足"长序列便宜"和"关键信息精确"两个约束，就用两种各偏一头的机制交替。总账：1M 上下文下 FLOPs 27%、KV 10%，且在 MRCCR 1M 等长上下文基准上保持竞争力（V4-Pro 83.5，Opus-4.6 为 92.9——见 [专题学习/DeepSeek-V4-Pro-Benchmark分析.md](#)）。

与 **Week 13** 的呼应：RULER 教我们区分"声称上下文长度 vs 有效上下文长度"。V4 的 CSA+HCA 就是架构侧对这道裂缝的正面回应——不仅声称 1M，还让 1M 下的计算与显存落到服务可承担的区间。评测侧（W13）与架构侧（本周）在此闭环。

2.4 训练栈工程：Muon、FP4 QAT、Anticipatory Routing

架构创新的"下半场"在训练栈——V4 报告里这些名字值得记住：

- **Muon 优化器**（部分替代 Adam）：对动量做正交化（Newton-Schultz 迭代把更新矩阵投影到正交基），使每个参数维度的更新步长均衡，避免 Adam 的各维度步长失衡。DeepSeek 与 Qwen 3.8（Part 3）都采用了 Muon——2026 年它正在成为大模型训练的事实新标准。深层网络 + MoE 的路由矩阵对优化器步长极其敏感，Muon 的均衡性恰好对症；
- **FP4 QAT**：权重精度从 FP8（V3 首创大规模工程化）进一步降到 4 bit，QAT（量化感知训练）在训练中模拟量化误差。精度每降一半，HBM 容量与带宽压力减半（见 W6 量化的推理收益）；QAT vs PTQ 的取舍见 W6——规模到了，训练时多花的成本换推理时全生命周期的节省；

- **Anticipatory Routing**: MoE 路由的"预期性"稳定化——超稀疏 MoE 的负载均衡是训练稳定性的核心难题（Kimi 用 Quantile Balancing 解同一道题，见 4.2），DeepSeek 的解法是让路由"预见"专家负载再分配；
- **SwiGLU Clamp**: 对激活函数输出做幅度钳制——W2 讲过 SwiGLU 的门控可能产生大激活值，深层 + 低精度训练下这会直接引发数值溢出，clamp 是工程兜底。

一个观察：V4 的创新清单里，"训练稳定性工程"占了一半以上。1M 上下文 + 100+ 层 + FP4 + 超稀疏 MoE，四个难度放大器叠加，每引入一个都要配一套稳定性机制——架构创新的真实成本在配套工程，这是读技术报告时最容易低估的部分。

2.5 V4.1 Flash：非对称编解码

V4.1 系列（Flash 版 2026-09-10 发布）引入了一个教科书级的新设计：**Causal-Encoder-Decoder（因果编码器-解码器）**。

关键参数：总参数 552B，输入侧每 token 激活约 8B，输出侧每 token 激活约 16B——两侧激活量差一倍。

为什么这样设计？回顾 W6 的推理不对称性：

阶段	计算特征	瓶颈	最优架构倾向
Prefill（处理输入）	计算密集（并行处理全部输入 token）	FLOPs	小而快的模型（算得快）
Decode（生成输出）	访存密集（逐 token 增量生成）	显存带宽	KV Cache 小、容量大的模型

旧架构（Decoder-only）两侧共享同一套参数与激活量，只能在"prefill 友好"与"decode 友好"之间折中。V4.1 的做法：给编码侧配轻激活（8B，吞吐优先），给解码侧配重激活（16B，质量与缓存效率优先）——把 W6 理论课讲的"不对称"直接烧进架构。

这与 W6 讲的 Chunked Prefilling、W8 的 Qwen3.5-Omni Chunked Prefilling 是同一主题的三个层次：调度层优化 → 编码器输出策略 → 模型结构本身的非对称化。

命名提示：注意"Causal"前缀——编码器仍用因果掩码（非传统 NMT 的双向编码器），保留自回归预训练范式的兼容性，这是能复用海量 next-token-prediction 数据的关键工程决策。

2.6 性能画像与定位

基于 `专题学习/DeepSeek-V4-Pro-Benchmark分析.md` (2026-04 benchmark 数据) 的画像：

- **编程：全场最强** (LiveCodeBench 93.5、Codeforces Rating 3206 均第一) ——可量化、有明确答案的工程类任务上表现卓越，DeepSeek 一贯风格；
- **数学：一线水平** (IMOAnswerBench 89.8, 第二) ；
- **前沿推理与事实知识：明显短板** (Apex 38.3 vs Gemini-3.1-Pro 60.9；SimpleQA-Verified 57.9 vs 75.6) ——超出训练分布的极端推理与幻觉抑制上，与第一梯队有差距；
- **长上下文：中等偏强** (MRCR 1M 83.5, 第二) ；
- **Agent：中规中矩** (SWE Verified 80.6 并列第一，但 Terminal-Bench 67.9 第四) 。

读法 (用 W12-W13 的评测素养)：技术报告的效率叙事 (FLOPs 27%/KV 10%) 是可信的工程事实；能力画像则要用"分数是系统属性"的眼光看——V4 的 profile 与其架构取向 (工程效率极致) 高度自洽：**架构决定性格**。

2.7 DeepSeek-OCR：视觉压缩的跨模态延伸

V4 家族同期还有 DeepSeek-OCR 值得一提：用 LLM 风格的架构 (而非 CLIP 式对比学习编码器) 处理视觉 token，通过**因果注意力掩码**让视觉 **token** 根据语义动态重排序，把"视觉压缩处理长文本"作为多模态入口——思想上与 CSA/HCA 的"压缩保语义"一脉相承。此方向与你的实战方向 (Qwen-VL) 相关，值得留意其后续演进。

Part 3: Qwen3.8-Flash-Next 解析

3.1 定位：Qwen4 架构的公开预演

Qwen3.8-Flash-Next (2026-08-26, 开源权重 preview) 官方定位是**Qwen4 架构预览**：主模型 125B 参数 + 51B N-gram Embedding + ~4B MTP 模块，磁盘总量约 180B，**每 token 激活仅 6B** (激活比约 1/21——超稀疏 MoE)。原生上下文 262,144 token；正式版 Qwen3.8-Flash 默认 1M 上下文 + 官方内置工具。

Qwen 官方架构论文 (arXiv 2608.30320, *On the Design of Qwen3.8-Next Architecture*) 的三个主题：评测 (Evaluation)、效率 (Efficiency)、训练稳定性 (Training Stability) ——与 DeepSeek V4 的议程高度重叠，再次印证收敛。

3.2 五层解耦：一张参数的分类账

Qwen3.8-Flash-Next 最反直觉的设计是**参数的角色分离**。传统上我们说"一个 125B 模型"，隐含假设所有参数是同质的；Qwen3.8 把它们拆成五层，各自遵守不同的物理规律：

层	参数量	每次推理是否激活	存放位置	本质角色
主模型容量	125B (MoE, 大专家池 + 少量路由 + 1 共享专家)	每 token 激活 6B	GPU 显存	可计算的推理能力
N-gram Embedding	51B	不激活, 纯查表	Host RAM (CPU 内存)	显式记忆
MTP 模块	~4B	推测解码时使用	GPU 显存	投机解码加速器
多模态编码	(随输入)	有输入时激活	GPU 显存	视觉/音频入口
残差流扩展 (GR)	(含在主干)	激活	GPU 显存	深度维信息通路

为什么这是深刻的设计：它承认了"知识 ≠ 计算"。W9 记忆系统讲过参数化记忆（权重里的隐式知识）与外部记忆（RAG、文件系统）的光谱——51B N-gram Embedding 恰好落在光谱中段：**它是一块不参与梯度计算（推理时纯查表）、可以放在便宜介质上的"记忆硬盘"：**

- 参数化知识 (MoE 权重)：计算获得，灵活但昂贵（必须过 GPU 矩阵乘）；
- **N-gram 查表知识：零计算获得，死板但近乎免费** (host RAM 的价格/容量比 GPU 显存低两个数量级，配合预取管线几乎不增加延迟)；
- 外部知识 (RAG)：检索获得，最新鲜但需要额外系统。

N-gram 表存的是文本片段的共现统计（衔接 W9 的"程序性/词法记忆"概念）——对语言建模这种大量依赖局部词法模式（搭配、固定表达、专名）的任务，把这部分"死记硬背"外包给查表，主干 MoE 就能专注于真正需要推理的知识。这是"把记忆从计算中剥离"的第一次架构级落地，其意义可能超过本周任何单项注意力创新。

3.3 GDN + QSA 3:1 混合注意力

Qwen3.8 的注意力层按 **3:1** 交替：每 4 层中 3 层 GDN、1 层 QSA。这条路线在 W8 讲 Qwen3.5-Omni 时已经铺过理论地基，此处从架构设计视角加深：

GDN（Gated DeltaNet，3/4 的层）——线性注意力，负责吞吐：

- 用固定大小的循环状态替代 KV Cache：每来一个 token，状态做一次"门控 + delta 更新"（选择性写入/覆盖/遗忘），复杂度 $O(n)$ 、状态大小恒定；
- 天然适合**流式处理**与超长序列的吞吐（这是 1M 上下文 prefill 7.6x 加速的主力）；
- 代价：精确 recall 弱（见 W8 的"效率 vs recall 权衡"）。

QSA（Qwen Sparse Attention，1/4 的层）——稀疏检索，负责精确性：

- 与 GDN 不同，QSA 是在**标准注意力上做"先压缩索引、再稀疏计算"**：一个轻量的 Indexer 网络先把上下文组织成 micro-block（微块），并为每个块打重要性分；每个 query 只对高分的少量块做完整注意力；
- 与 DeepSeek CSA 的"块合并 + top-k"是同构思想（不约而同的收敛），区别在 Qwen 的 Indexer 是学习的压缩式打分器，DSA 是索引选择；
- MTP 模块也用 QSA，且**投机解码的多个候选步复用同一批 QSA 索引**——加速器与检索机制共享，工程上很漂亮。

3:1 配比的含义：大部分层走 $O(n)$ 快通道，少数层做精确检索"纠偏"。这与 DeepSeek 的 CSA/HCA 交替、人脑的 System1/System2 是同一设计模式的三次独立发现：**混合不是因为技术不成熟，而是"效率与精确 recall 不可兼得"是任务本质。**

3.4 Gated Residual 与训练稳定性

Qwen3.8 的每个子层读写都经过 **GR（Gated Residual）**：残差流被拓宽，且每个子层读取残差流时经过一个**逐元素门控**——网络可以学习"屏蔽掉残差流中与自己无关的通道"，写入时同样有门控。

与 mHC (2.2) 对照着读最有意思：GR 和 mHC 都在解决"多路/宽残差流的信号管理"，但：

- **mHC 用硬约束**（双随机矩阵，数学保证总量守恒）；
- **GR 用软门控**（学习出来的 elementwise 掩码，灵活性最大但无数学保证）。

加上 Qwen3.8 也换用了 **Muon 优化器**（与 DeepSeek 同款），训练稳定性工具箱在三家里开始出现明显的交叉复用——**Muon 正在成为 2026 年大模型训练的事实标准**，这个趋势对做训练工程的人（包括你的实战项目）是直接相关的信号。

3.5 效率数字解读

官方报告的 1M token 场景数字（对照 Qwen3.7-Plus）：

- Prefill **7.6x** 加速：GDN 线性层扛住大部分 token 的 $O(n)$ 处理 + QSA 稀疏索引；
- Decode **4.9x** 加速：固定状态无 KV Cache 膨胀 + N-gram 查表不占 GPU 带宽；
- 稳态吞吐（带前缀缓存）**8.6x**：前缀缓存（见 W15 将讲的 Prefix Caching）与查表记忆的叠加收益。

用 **W6 的推理工程眼光**读这些数字：加速倍率都来自"减少访存 + 减少计算"两个杠杆的同时压榨；且注意"带缓存"与"不带缓存"的口径差异——W12/W13 反复训练过的"分数是测量系统的属性"，对效率数字同样成立。

Part 4: Kimi K3/K2.8 解析

4.1 定位与产品策略

Kimi K3（2026-07-16 API 发布，2026-07-27 开源权重 + 47 页技术报告）：2.8T 总参数（当前最大开源权重模型）、原生视觉、1M token 上下文（较 K2 的 256k 扩大 4 倍），能力咬住闭源第一梯队，开源第一。

K2.8 Preview（2026-09-11）：闭源的中间层多模态模型，定位在 K2.7 Code 与旗舰 K3 之间，性能接近 K3，API ID 保持 `kimi-for-coding` 不变（客户端零改动）。

产品策略的读法（Phase 5 的商业视角）：K3 开源打生态位与口碑，K2.8 闭源收编企业付费场景——开源旗舰 + 闭源中间层的"高低搭配"是 2026 年国产厂商的典型打法（对比 DeepSeek 全开源路线、Qwen 的 open-weight preview→正式版节奏）。架构学习的素材主要来自 K3 技术报告。

4.2 超稀疏 MoE：896 选 16 与 LatentMoE

K3 的 FFN 侧配置：**896 个专家，每 token 激活 16 个（Top-16）**，稀疏比 56:1，每 token 激活约 104B（约占总参 1/27）。

对比 W2 的 MoE 谱系表：Qwen2-57B 是 Top-8（激活比 $\sim 1/7$ ），DeepSeek-V3 是 256 选 8（Sigmoid 独立打分），K3 把稀疏度再推一个数量级。**稀疏度越高，"知识容量 vs 单 token 计算"的解耦越极致**（2.8T 容量配 104B 计算），但负载均衡的难度也非线性上升——896 个专家中任何一个被冷落/过热，训练就会崩溃或浪费。

K3 的两件新武器：

- **Stable LatentMoE**：路由不在"专家参数空间"直接做，而在一个学习到的**潜在空间**里组织路由（提高路由的泛化性与稳定性）；
- **Quantile Balancing**：按路由分数的**分位数**分配专家负载，替代传统辅助损失/启发式更新。回忆 W2：DeepSeek-V2 用"无辅助 Loss 的负载均衡"（更新偏置项）解决 Top-k 竞争；Quantile Balancing 是同一条"去辅助损失"路线的后续——辅助损失与主损失的梯度冲突问题（W2 已讲）在 56:1 稀疏度下更尖锐，必须用不进梯度的机制解。

报告称 K3 相比 K2 的**整体扩展效率提升约 2.5 倍**（同等算力换更多能力）——超稀疏 MoE + 架构升级的共同贡献。

4.3 KDA：从标量遗忘到逐维遗忘

K3 的注意力主干是 **KDA（Kimi Delta Attention）+ MLA 混合**（来自 Kimi Linear 研究线，2025-10 起步）。KDA 是对 Gated DeltaNet（W8、Part 3 已铺垫）的一次精确改进，值得用数学写清楚，因为它体现了"识别瓶颈→最小改动"的品味。

GDN 的遗忘机制：循环状态 S_t 的更新形如

$$S_t = \alpha_t S_{t-1} + \beta_t \cdot (\text{新信息})$$

其中 $\alpha_t \in (0, 1)$ 是一个**标量衰减因子**——状态的所有维度以同一个速率遗忘。

问题：记忆的不同通道需要不同的遗忘速率。比如处理一段代码时，"变量名"通道需要保持（后面还要用），"空格排版"通道可以立刻遗忘——**标量衰减是维度级的钝刀**。

KDA 的改进：把标量换成向量，展开为**对角矩阵** $\text{diag}(\alpha_t) \in \mathbb{R}^{d \times d}$ ：

$$S_t = \text{diag}(\alpha_t) S_{t-1} + \Delta_t$$

每个状态维度获得**独立的遗忘率**——通道级的精细控制。代价是对角矩阵乘法比标量乘贵一点，但 Kimi 的工程优化（关联 chunk 级并行）把它做到了可扩展（2.8T 规模落地验证）。

一句话总结 KDA：GDN 让模型"能遗忘"，KDA 让模型"每个记忆通道按需遗忘"——这是把"选择性记忆"从层级别下放到维度级别的精度提升。

4.4 AttnRes：深度维的选择性检索

K3 对残差连接的解法（AttnRes, Attention Residuals）与 mHC 方向截然相反，是本周最重要的对比素材。

旧范式（标准残差）：

$$h_L = h_0 + F_1(h_0) + F_2(\cdot) + \dots$$

每一层的输出以**相等的权重**累加进残差流。问题（Kimi 的诊断）：随深度增长，每层的贡献被**稀释**——第 100 层的输出与前面 99 层的输出等权求和，模型无法"重点参考"某几个关键层。

AttnRes 的设计：把层间信息传递变成**注意力**——每层（实际是每个 Block，见下）的输出作为 key/value，一个可学习的**伪查询**（pseudo-query）向量做 softmax，对前序所有层的表征加权检索：

$$h_{\text{out}} = \sum_l \text{softmax}(q_{\text{pseudo}} \cdot k_l) v_l$$

深度的注意力化：从此每一层可以**动态、按输入内容**地决定"重点继承哪些前层的表征"——固定求和是"所有前辈等权发言"，AttnRes 是"轮到谁发言由内容决定"。

两个关键工程细节：

1. **伪查询零初始化**：训练初期 softmax 权重均匀 → 等价于标准等权平均（与 W3 LoRA 的 B 零初始化是同一思想：**新机制起步时必须退化为旧机制，保证训练不倒退**）；
2. **Block 变体**：不对每层做注意力（开销 $O(L^2)$ ），而是把层分组成 N 个 Block，Block 间做 AttnRes、Block 内标准残差——把深度注意力的开销控制住（这是 2.8T 规模落地的必要工程化）。

4.5 KDA vs AttnRes vs mHC：三个坐标轴

Kimi 官方的一句话总结非常精准：**"KDA 是时间维的选择性遗忘，AttnRes 是深度维的选择性检索"**。加上 DeepSeek 的 mHC，三家对信息流的手术可以放进一个二维坐标：

机制	维度	操作	约束哲学
KDA	时间维（序列轴）	逐通道选择性遗忘	软机制（学习门控，无硬保证）
AttnRes	深度维（层轴）	选择性检索前层	软机制（softmax 权重，零初始化保护）
mHC	深度维（层轴）	总量守恒的混合	硬约束 （双随机流形，数学保证）

AttnRes vs mHC 的哲学对比（建议作为深度思考题）：

- 两者都承认"固定残差求和"已经过时；
- mHC 走**约束路线**：先保稳定（范数有界），表达能力在约束流形内优化——**悲观主义工程**（假设自由度会失控）；
- AttnRes 走**表达路线**：先要灵活（内容相关的层间路由），稳定性靠初始化与 Block 化控制——**乐观主义工程**（假设自由度能被学习驯服）；
- 有趣的是两条路线在 2026 年同时落地到万亿级模型，且各自报告了正收益。**深度维设计空间还远没有收敛**——这是与"注意力层 MHA→GQA 已收敛 10 年"形成鲜明对比的开放前沿。

4.6 评测侧速览

K3 的公开评测要点（用 W12/W13 的防御性阅读姿势）：代码/Agent 能力是主打（对齐 K2.7 Code 的产品线惯性），通用推理第一梯队；具体分数建议跟踪 Arena 与 SWE-Bench Verified 的（模型 × harness）条目而非厂商自报数字（W13 的 Agent 分数公式直接适用：K3 的 1M 上下文 + Agent 能力分数，必须先问 harness 与评测环境版本）。

Part 5: 三家横向综合

5.1 收敛主题总结

把三家的创新并排放，五个收敛主题清晰可见：

主题	DeepSeek V4	Qwen3.8	Kimi K3	共同动机
序列维压缩	CSA+HCA 交替	GDN+QSA 3:1	KDA+MLA 混合	1M 上下文的计算/显存可行性
深度维重构	mHC（硬约束）	Gated Residual（软门控）	AttnRes（层间注意力）	100+ 层的信号管理与训练稳定
超稀疏 MoE	DeepSeekMoE 细粒度	大池+少路由+共享专家	896选16 + LatentMoE	知识容量与单 token 计算解耦
显式记忆回归	（无）	51B N-gram 查表	（无）	记忆与计算的成本分离
训练稳定性工程	Muon/FP4/AR/SwiGLU-Clamp	Muon/GR	Quantile Balancing	更深+更稀疏+更低精度的叠加风险

收敛的原因不是抄作业（三家技术报告的引用关系显示是并行独立探索），而是**外部约束相同**：1M 上下文成为标配、Agent 时代的推理成本压力、训练硬件的性价比极限。同一道考题，三份接近满分的答案——这比任何单项创新都更能说明**这些主题是下一代的"标准件"候选**。

5.2 分歧点：路线选择的性格差异

收敛中有分歧，且分歧与各家"性格"（产品定位/资源禀赋）高度相关：

分歧点	DeepSeek	Qwen	Kimi
长上下文主力机制	压缩+稀疏（在注意力框架内改造）	线性注意力为主（跳出 KV Cache 范式）	线性注意力精细化（GDN 微调）
残差哲学	数学约束（稳）	门控（中）	注意力（活）
记忆外置	无	51B 查表 （独此一家）	无
非对称设计	编解码两侧激活不对称 （独此一家）	无	无
稀疏度	中等	中等	56:1 最激进

读法：DeepSeek 的两件独家武器（非对称编解码、极致 KV 压缩）都指向"推理服务成本"，与 V4 主线一致；Qwen 的独家武器（N-gram 记忆外置）指向"容量成本分离"，与其多模态 + 全模态产品矩阵的大容量需求一致；Kimi 的激进稀疏度指向"最大知识容量"，与其开源旗舰打口碑的定位一致。**架构是产品战略的函数**——这句话可以作为 Phase 7 的主题句。

5.3 对"Transformer 后时代"的判断

本周证据支持的判断（供批判性讨论，非定论）：

- Transformer 不是被替代，而是被"逐件拆修"：**注意力的 $O(n^2)$ 、残差的固定求和、FFN 的稠密计算、Adam、BF16——五个组件全部在 2026 年被重写，但"堆叠的序列处理网络"这个骨架仍在。类比内燃机到电动车的过渡：动力系统换了，"车"的概念没换；
- 混合架构是终局而非过渡：**"线性层扛吞吐 + 稀疏/全注意力层保 recall"在三家全部落地，说明这不是技术不成熟的妥协，而是任务本质决定的双系统需求（人脑的 System1/System2 同构）；

3. 下一个悬念在深度维：注意力序列维的答案已收敛（混合），但 mHC/AttnRes/GR 三条残差路线还在分叉——关注 2026-2027 年哪家先给出"深度维设计空间收敛"的证据；
 4. 记忆的形态光谱正在被工程化：从纯参数化（旧）→ RAG 外挂（W9）→ 架构内查表，三档成本/灵活性不同的记忆形态将共存——Qwen 的 N-gram 表是第一条被万亿级模型验证的中间路线。
-

Part 6: 前沿发展速览

各家最新动态（截至 2026-09）：

- **DeepSeek**：V4.1 Flash（2026-09-10）以 552B/8B-16B 非对称编解码成为新架构系列最小成员；V4-Flash 用 32T、V4-Pro 用 33T token 预训练；mHC 论文（arXiv 2512.24880）被视为 2026 开年最有影响力的架构论文之一；MIT 协议 + 完整技术报告的开源姿态延续；
- **Qwen**：3.8-Flash-Next（2026-08-26）为 Qwen4 预演；正式版 3.8-Flash 默认 1M 上下文 + 官方内置工具；架构论文（arXiv 2608.30320）公开了评测/效率/稳定性三个维度的完整实验，是学习"架构研究方法论"的好材料；vLLM/SGLang day-0 支持其开源权重；
- **Kimi**：K3 开源（2026-07-27）+ 训练与算子基础设施同步开放（对研究者极有价值）；K2.8 Preview（2026-09-11）闭源中间层上线 Kimi Code/Work，可调思考档位；AttnRes 论文获马斯克与 Karpathy 公开点赞，学术影响力破圈；
- **横向观察**：Muon 优化器在三家的交叉采用是最强的"事实标准"信号；1M 上下文已从旗舰特性降级为"标配"；每家都在"开源旗舰打口碑 + 闭源/服务版本收收入"的商业结构上做文章。

值得关注的方向（衔接 W15）：Prefix Caching 与混合注意力的叠加收益（Qwen 吞吐 8.6x 的构成）、MTP 与稀疏注意力的索引复用（投机解码的架构协同）、非对称编解码对 Agent 场景（长 prompt + 短输出的典型负载）的意义。

💡 实践启示

1. **对微调实战 (Qwen-VL + CameraBench) 的直接意义**：本周三家全部在动"注意力与残差"，而 LoRA 微调时 target_modules 的选择 (W3 的 q/k/v/o/gate/up/down) 在新架构下将发生变化——GDN 层的 delta 更新矩阵、QSA 的 Indexer、GR 的门控都可能成为新的高效微调目标。做实战时先看一眼所用 backbone 的架构再定 target_modules；
2. **推理部署选型**：1M 上下文需求下，backbone 的注意力机制 (CSA/HCA、GDN+QSA、KDA) 直接决定服务成本量级——选型时"每百万 token 的推理成本"应成为与"基准分数"并列的第一指标 (W13 的评测素养直接落地)；
3. **架构阅读姿势**：读技术报告先找"主线命题" (V4 的 1M 日用化、Qwen 的容量解耦、K3 的信息流动)，所有单项创新都能挂回主线——**没有主线的创新清单通常意味着工程拼凑，有主线的才值得精读**；
4. **训练工程的迁移信号**：Muon、量化感知训练、路由稳定性机制正在标准化——这些不是"万亿俱乐部专属"，中小规模训练 (包括实战项目的 LoRA/full FT) 也在快速吸收同款思想 (如 QAT 思想的 LoRA 变体)。

✅ 检查点

- [] 能画出主流模型 (GPT-3/LLaMA/Qwen/DeepSeek) 的技术选择对比表
- [] 理解从 GPT-3 到 LLaMA 的关键架构变化及其动机
- [] 理解演进"两股绳" (能力 vs 效率) 与 2025-2026 五条战线
- [] 理解 mHC 如何用双随机矩阵流形约束解决深层网络训练不稳定性 (Birkhoff 定理直觉)
- [] 理解 CSA+HCA 如何分别对付计算与显存，及"MLA 压宽度不压条数"的 1M 瓶颈
- [] 理解 V4.1 非对称编解码与 W6 prefill/decode 不对称性的同源关系
- [] 理解 Qwen3.8 五层解耦，特别是 51B N-gram 查表记忆的"记忆与计算成本分离"意义
- [] 理解 GDN+QSA 3:1 混合与 DeepSeek CSA/HCA 的同构性 (混合是终局)
- [] 理解 KDA 的对角遗忘与 AttnRes 的深度注意力，及其"软机制 vs mHC 硬约束"的哲学对比
- [] 能说出三家收敛的五大主题与各自的独家武器，并解释"架构是产品战略的函数"

A.1 双随机矩阵与 mHC 的数学细节

关联正文：2.2 节 mHC

定义： 矩阵 $M \in \mathbb{R}^{n \times n}$ 是双随机的，当且仅当 $M_{ij} \geq 0$ 且 $\sum_j M_{ij} = 1$ （行随机）、 $\sum_i M_{ij} = 1$ （列随机）。

Birkhoff-von Neumann 定理： 双随机矩阵集合（Birkhoff 多胞形）恰好是全体 $n!$ 个置换矩阵的凸包：

$$M = \sum_{\pi \in S_n} \lambda_{\pi} P_{\pi}, \quad \lambda_{\pi} \geq 0, \quad \sum_{\pi} \lambda_{\pi} = 1$$

信号传播的守恒证明（简版）： 对任意特征向量 x ， $\|Mx\|_1$ 的守恒由行随机性保证"总量不变"，列随机性保证"重分配不偏斜"。层层复合（乘积仍双随机）后，无论多少层，信号总能量既不指数放大也不衰减——这正是 ResNet 恒等映射性质的"可学习加强版"（恒等映射只是 $M = I$ 这一个点，mHC 把可用空间扩展到整个多胞形）。

Sinkhorn-Knopp 投影： 给定任意非负矩阵 A ，交替执行"行归一化 / 列归一化"迭代，收敛到双随机矩阵 $\Pi(A)$ 。复杂度低、可微（mHC 训练时梯度可穿过投影），这就是"流形约束"的落地机制。

A.2 CSA/HCA 分块压缩的代价分析

关联正文：2.3 节 CSA+HCA

以 1M token、head 维度 128 为例的粗账：

方案	KV 条数	每 query 计算量	精确 recall 风险
MLA (V3 基线)	$n = 1\text{M}$	$O(n)$ 全读	无（但贵）
CSA (m=4 + top-k)	$n/4$, 读 k 条	$O(k)$	中（4 合 1 有损 + 选择漏检）
HCA (m'=128)	$n/128 \approx 8\text{K}$	$O(n/128)$ 全读	高（128 合 1，细节必损）

混合交替的意义：HCA 层提供"廉价的全局轮廓"，CSA 层对关键区域做"精读"，两者信息在残差流中汇合——单层各有损，组合近似无损。注意这与 W13 RULER 的多跳任务（跨段落信息聚合）直接相关：压缩注意力的 recall 损失在 RULER 类任务上最先暴露，这是读 V4 长上下文分数时的背景知识。

A.3 KDA 遗忘机制的推导与 GDN 对照

关联正文：4.3 节 KDA

GDN（标量遗忘）：

$$S_t = \alpha_t S_{t-1} + \beta_t u_t v_t^\top, \quad \alpha_t \in (0, 1) \text{ 标量}$$

所有状态通道同速率衰减。等价于"整个记忆一个保质期"。

KDA（对角遗忘）：

$$S_t = \text{diag}(\alpha_t) S_{t-1} + \Delta_t, \quad \alpha_t \in (0, 1)^d \text{ 向量}$$

第 i 个通道的遗忘率由 $\alpha_{t,i}$ 独立控制。等价于"每个记忆通道自己的保质期"。例：通道 3 存"当前函数的返回类型"（长保质期， $\alpha \rightarrow 1$ ），通道 7 存"上一个标点"（短保质期， $\alpha \rightarrow 0$ ）。

为什么是对的改进方向：注意力 softmax 的每通道 logit 变化速率本就不同（W1 讲过的各维度语义分化），统一遗忘率与维度语义分化天然冲突；KDA 把遗忘的自由度对齐到语义自由度。代价：对角矩阵乘多 d 次乘法/步，工程上靠 chunk 并行摊销。

A.4 三家规格速查表

关联正文：Part 2/3/4

维度	DeepSeek V4.1 Flash	Qwen3.8-Flash-Next	Kimi K3
发布	2026-09-10	2026-08-26（Qwen4 预演）	2026-07-16 API / 07-27 开源
总参数	552B	180B（125B 主干 + 51B N-gram + 4B MTP）	2.8T
每 token 激活	输入侧 ~8B / 输出侧 ~16B（非对称）	6B	~104B
注意力	CSA+HCA 混合（MLA 系谱）	GDN+QSA 3:1（含 MLA 全注意力层）	KDA+MLA 混合
残差	mHC（双随机约束）	Gated Residual	AttnRes（Block 级层间注意力）
MoE	DeepSeekMoE + Anticipatory Routing	大池超稀疏 + 共享专家	896选16（56:1） + LatentMoE + Quantile Balancing
上下文	1M（原生）	262K 原生（正式版 1M）	1M
优化器/精度	Muon + FP4 QAT	Muon	-（报告中未完整披露）
独家武器	非对称编解码 / KV 压到 10%	N-gram 查表记忆外置	最激进稀疏度 / 记忆-检索双改
开源	是（MIT）	是（open-weight）	是（旗舰） / K2.8 闭源

表中数字来自各技术报告/官方页（2026-09 检索），以官方最新披露为准。

参考与延伸

- DeepSeek-V4 技术报告（2026-04-24，HuggingFace PDF）；mHC: arXiv 2512.24880

- Qwen3.8-Flash-Next: arXiv 2608.30320 (*On the Design of Qwen3.8-Next Architecture*) ; Qwen 官方博客
- Kimi K3 技术报告 (GitHub: MoonshotAI/Kimi-K3) ; Kimi Linear (KDA 出处) ; AttnRes 论文
- 本项目内: 专题学习/MLA专题讲义.md (MLA 完整数学)、 专题学习/DeepSeek-V4-Pro-Benchmark分析.md (V4 能力画像)、 W1/W2 (标准件原理)、 W6 (推理不对称性)、 W8 (GDN 理论地基)、 W9 (记忆系统光谱)、 W13 (长上下文评测侧)

下讲预告: Week 15 将继续 Qwen 全家桶 (VL/Omni 与 M-RoPE 细节)、面向 Agent 的架构优化 (Prefix Caching/并行工具调用/结构化输出), 以及持续学习 (Nested Learning/HOPE) 与模型融合 (Task Arithmetic/TIES/DARE) ——其中模型融合与本周的"权重空间"讨论 (mHC 的层间混合、AttnRes 的表征检索) 将形成"训练时融合 vs 训练后融合"的完整对照。